빅데이터 분석기사 필기 완벽 마스터 노트

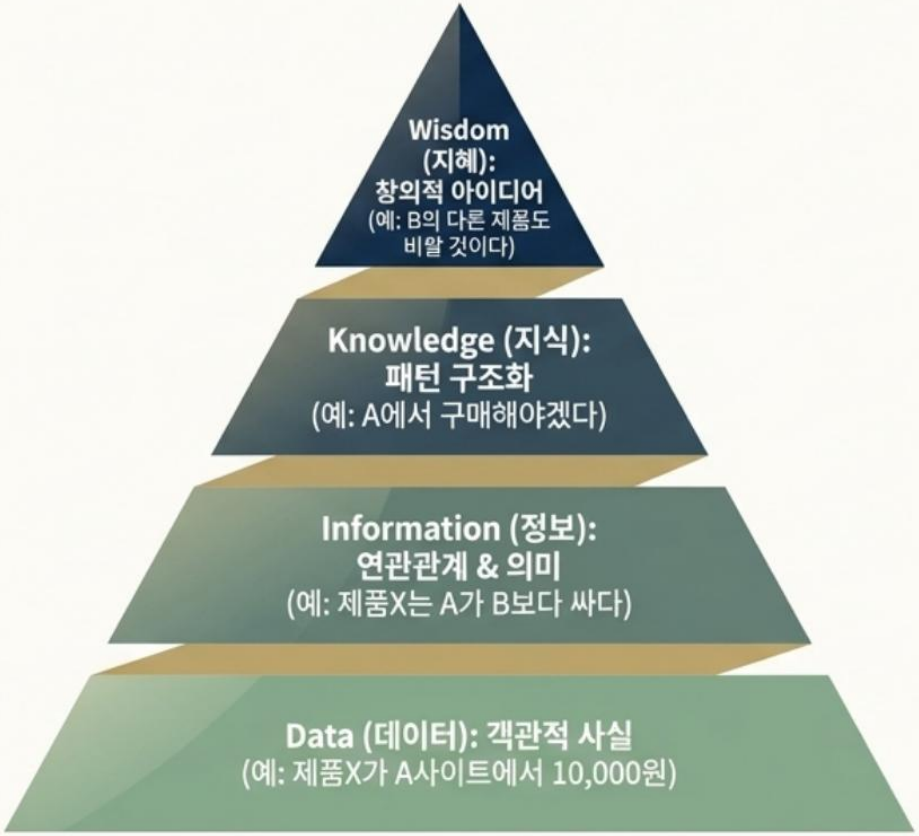
데이터 설계자의 청사진: 이해부터 암기까지 단권화 마스터클래스

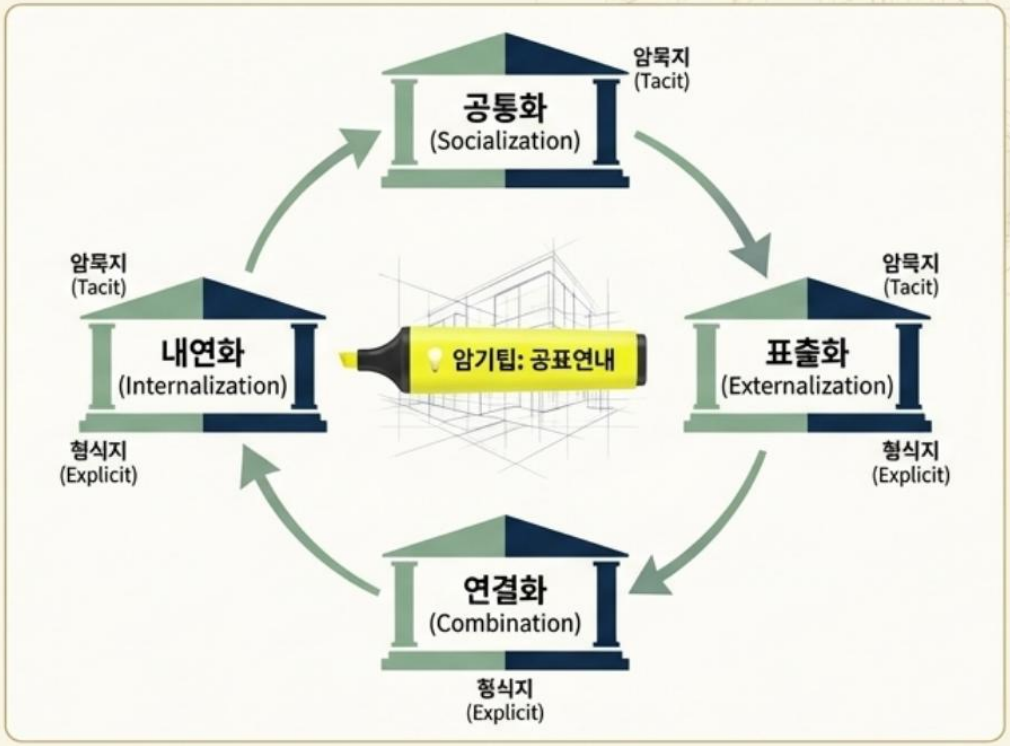
학습 가이드 (How to use this guide)

[암기팁]: 시험에 무조건 나오는 핵심 암기 공식

[Teacher's Note]: 직관적인 이해를 돕는 현실 비유와 심화 설명

데이터의 가치 창출과 지식의 상호작용





[Teacher's Note]: 요리사 비유를 기억하세요! 내 요리 비법(암묵지)을 조수에게 발로 전수하면 '공통화', 블로그에 글로 적으면 '표출화', 블로그 글에 새 레시피를 덧붙이면 '연결화', 다른 사람이 그 글을 보고 직접 요리하며 체득하면 '내연화'입니다.

비유로 이해하는 데이터베이스(DB) 아키텍처

스키마 (Schema):
전반적인 명세, 도면

메타데이터 (Metadata):
데이터를 설명하는
데이터(라벨)

데이터 사전 (Data Dictionary):
시스템에 저장된 개체 정보
종합 안내 책자



인덱스 (Index):
정렬 및 탐색을 위한
보조 도구 (구역 번호)

인스턴스 (Instance):
저장된 데이터 그 자체

DB의 4대 특징

💡 **암기팁: 공통저변**

- 공용 (Shared), 통합 (Integrated - 중복X)
- 저장 (Stored), 변화 (Operational - 무결성 유지)

기업 내부 DB 활용 사례

💡 **설계 순서:** 개논물 (개념 ➡ 논리 ➡ 물리)

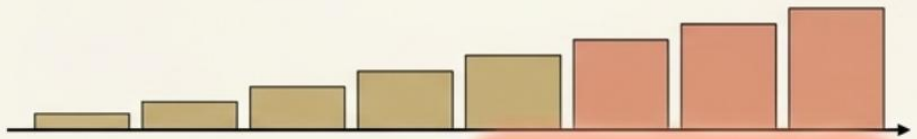
👨‍🏫 [Teacher's Note]: 영문 풀네임으로 이해하세요!
OLTP (Transaction = 거래), OLAP (Analytics = 분석 다차원),
CRM (Customer = 고객관계), SCM (Supply = 공급망),
ERP (Enterprise Resource = 전사적 자원).

빅데이터의 출현과 본질적 변화

가트너(Gartner)의 빅데이터 3V : Volume (규모) + Variety (다양성) + Velocity (속도)

(확장: Value 가치, Veracity 신뢰성)

데이터 단위 체계



KB ➡ MB ➡ GB ➡ TB ➡ PB ➡ EB ➡ ZB ➡ YB

암기팁 : 페지요 (PB ➡ EB ➡ ZB ➡ YB. 짜증나는 선배? '페지요'!)

빅데이터 활용 3대 요소



빅데이터가 만들어내는 본질적 변화

표본 조사 ➡ 전수 조사

사전 처리 ➡ 사후 처리

암기팁: 전후양상

데이터의 질 ➡ 데이터의 양

인과 관계 ➡ 상관 관계

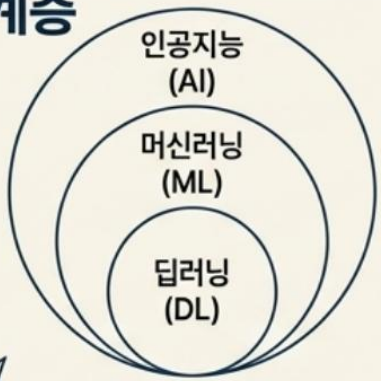
조직 구조, 인공지능 계층, 그리고 데이터 법제도

빅데이터 조직 구조 3가지

💡 암기팁: 집기분

수직 업무활동	수평 업무활동	집중 구조	기능 구조	분산 구조
우선순위 결정	프로세스별로 업무 배분	별도 전담부서 우선순위 지정가능	해당 부서에서 분석 전사적 분석 어려움	각 부서로 배치 베스트 프랙티스 공유

인공지능의 계층



👨‍🏫 [Teacher's Note]: 정답을 주면 '지도학습'(개/고양이 사진), 정답 없이 특징만 찾으라 하면 '비지도학습', 보상을 위해 스스로 깨우치면 '강화학습'(알파고) 입니다.

개인정보보호와 데이터 3법 (💡 암기팁: 개정신)

핵심: '가명정보' 개념 도입. (가명처리 시 통계 작성, 과학적 연구 목적으로 동의 없이 활용 가능!)

사전 검토 → 비식별 조치 → 적정성 평가 → 사후 관리

분석 문제 정의와 프로젝트 우선순위 선정

하향식 vs 상향식 접근법



👨‍🏫 **[Teacher's Note]:** 식당 컴플레인 비유! 머리카락 나온 요리를 당장 환불해주는 과제 중심적 접근과, 주방 위생부터 근본적으로 뜯어고치는 장기적 마스터 플랜 접근이 있습니다.

하향식 (Top-Down)	상향식 (Bottom-Up)
문제(Known) ➡ 해답(Unknown) 찾기. (문제 탐색 ➡ 정의 ➡ 해결방안 ➡ 타당성 검토). 💡 **탐색 5요소 암기**: 지원 인프라 업무 중 고객이 제품을 규제와 감사했다.	문제(Unknown) ➡ 해답(Known). 정답을 모를 때 쓴다. (비지도 학습, 프로토타이핑).

과제 우선순위 선정 (ROI 관점)





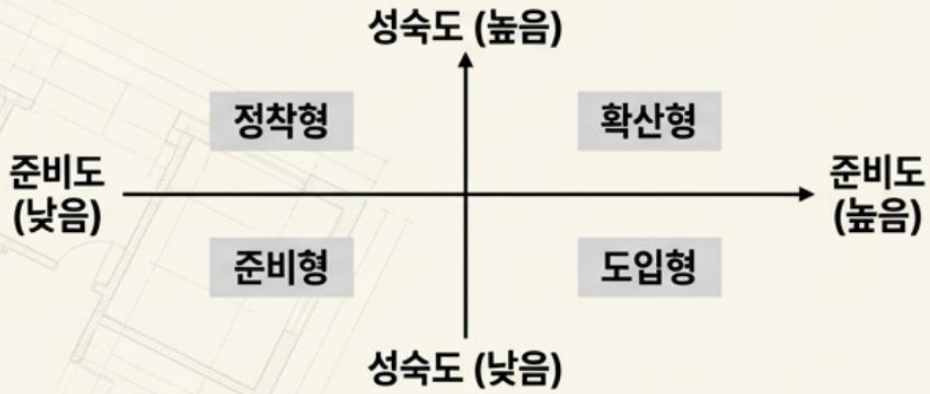
💡 **[우선순위 결정 로직]**
시급성 기준: 3 ➡ 4 ➡ 2 (현재 가장 급한 것을 끌어와서라도 먼저!)
난이도 기준: 3 ➡ 1 ➡ 2 (어려운 것을 쉽게 만들어서라도 먼저!)

빅데이터 분석 방법론 및 분석 성숙도 모델

3대 빅데이터 분석 방법론 비교

KDD (프로파일링 중심)	CRISP-DM (비즈니스 이해 중심)	SEMMA (통계 중심)
데이터 선택 ➡ 전처리 ➡ 변환 ➡ 마이닝 ➡ 결과 평가	업무 이해 ➡ 데이터 이해 ➡ 데이터 준비 ➡ 모델링 ➡ 평가 ➡ 전개 ⚠ 주의: 모델링 단계에서 '모델 평가', 평가 단계에서 '모델 적용성 평가' 수행!	Sampling ➡ Exploration ➡ Modification ➡ Modeling ➡ Assessment

데이터 분석 성숙도 모델



💡 **암기팁: 도준정확**

- **도입형**: 분석을 이제 막 시작 (준비도↓, 성숙도↑)
- **준비형**: 환경·인프라 정비 중 (준비도↓, 성숙도↓)
- **정착형**: 분석 업무 정례화 (준비도↑, 성숙도↓)
- **확산형**: 전사 차원 확대 (준비도↑, 성숙도↑)

데이터 플랫폼 아키텍처: 수집과 저장

수집 및 분산 처리 기술

ETL: 추출(Extract) ➡ 변환(Transform) ➡ 적재(Load). 전통적 수집 방식.

SQOOP: RDBMS와 하둡 간 대용량 데이터 전송.

HDFS (하둡 분산파일 시스템): 네임노드(Master) + 데이터노드. 기본 3개 서버에 복제하여 장애 대비.

MapReduce: 데이터를 쪼개서 매핑(Mapping)하고 섞은 후(Shuffling) 결과를 집계(Reducing)하는 병렬 처리 모델.

데이터 저장소 완벽 비교

데이터 웨어하우스 (DW)	데이터 마트 (DM)	데이터 레이크 (Data Lake)
정형 데이터의 거대한 창고. 주제지향성, 통합성, 시계열성, 비휘발성.	DW의 소규모 버전. 특정 목적을 위해 요약된 정보 모음 (요약변수 위주).	비정형 데이터를 원형 그대로(Raw) 때려 넣는 거대한 호수. 하둡과 주로 연계.

데이터 전처리: 차원 축소와 변수 변환

차원의 저주와 차원 축소 비교

PCA (주성분 분석)	요인 분석 (Factor Analysis)
상관성 높은 변수들을 선형 결합해 새로운 축 생성. 목적: 정보(분산) 손실 최소화. 직교 변환 사용.	변수들 내부의 '잠재된 공통 원인(요인)' 도출. 독립/종속 구분 없음. 기술통계 기반.

변수 변환 기법

수치형 변수 변환

- Z-score 정규화: (값 - 평균) / 표준편차
- Min-Max 정규화: (값 - 최소) / (최대 - 최소)

범주형 변수 변환

- 레이블 인코딩: 데이터를 단순 정수로 부여 (0, 1, 2...)
- 원-핫 인코딩: 해당 값만 1, 나머진 0으로 표기 (차원 증가 주의)

데이터 불균형 처리

언더샘플링 (다수 데이터 삭제) — 오버샘플링 (소수 데이터 복제)

💡 SMOTE

가상 직선을 활용해 소수 클래스 데이터를 '합성'하는 강력한 오버샘플링 기법.

탐색적 자료 분석 (EDA) 및 상관분석

EDA (탐색적 자료 분석)

목적: 모델링 전 데이터의 숨겨진 의미와 패턴을 직관적으로 파악

💡 암기팁: 저잔재현 (EDA 4가지 주제)

- 저항성 (이상치에 영향 적게 받음)
- 잔차 계산 (관찰값 - 적합값)
- 자료변수의 재표현 (로그 변환 등)
- 현시성 (그래프를 통한 시각화)

분포의 형태

첨도 (뾰족함, 기준 3), 왜도 (비대칭성. 양수면 오른쪽 꼬리가 김)

상관분석 총정리 매트릭스

	피어슨 (Pearson)	스피어만 (Spearman)
데이터 유형	연속형 수치 데이터	서열형(순서형)/연속형 데이터
관계 측정	선형(직선) 관계 측정	단조(비선형 포함) 관계 측정
계산 방식	값 자체를 연산	순위(Rank)로 변환해 연산
이상치 민감도	이상치에 매우 민감	이상치에 강함
예시	키와 몸무게	만족도 점수 순위

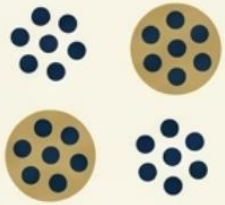
표본 추출 방법과 확률 분포의 세계

표본 추출 방법 4가지

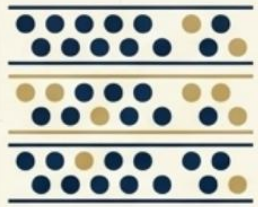


1. 랜덤 추출

2. 계통 추출



3. 집락(군집) 추출
그룹 내 이질, 그룹 간 등질



4. 층화 추출
그룹 내 등질, 그룹 간 이질

이산 확률 분포 (셀 수 있음, 확률질량함수)

💡 암기팁: 베포항항하

분포 이름	설명	예시	시험 포인트
이산균등분포	모든 값이 나올 확률이 똑같음	주사위, 복권 번호	확률이 전부 같음 (1/n)
베르누이분포	한 번 시행에 결과가 두 개뿐	동전 앞/뒤 (1=성공, 0=실패)	성공 확률 = p
이항분포	베르누이 시행을 n번 반복	동전 10번 던져 앞면 몇 번?	공식: $P(X=k) = {}^nC_k p^k(1-p)^{n-k}$
기하분포	처음 성공할 때까지 걸리는 횟수	몇 번째에 첫 정답 맞힘?	"처음 성공" 기억!
다항분포	결과가 여러 개일 때 확률	주사위 60번 던졌을 때 각 눈의 횟수	베르누이의 확장
포아송분포	단위 시간/공간에서 발생하는 사건 횟수	1시간 동안 들어오는 전화 수	"희귀 사건", λ(람다) 사용

연속 확률 분포 (구간 확률, 확률밀도함수)

분포 이름	설명	사옹 에	관련 검정
정규분포	종 모양, 평균 중심 대칭	키, 체중, 점수	Z-검정
t-분포	표본 적을 때 평균 비교	표본 수 적을 때 평균 비교	t-검정(2집단 평균 차이 검정)
카이제곱분포	한쪽으로 치우친 종 모양	범주형 변수 독립성 검정	카이제곱검정
F-분포	두 집단의 분산 비교	분산이 같냐 다르냐 확인	F-검정 (분산비 검정)
지수분포	사건 사이 시간 간격	기계 고장까지 걸리는 시간	생존분석 등

추론 통계: 가설검정과 오류의 이해

가설과 오류의 직관적 이해

- **귀무가설 (H0):** 차이가 없다 (버리기 위해 세우는 가설)
- **대립가설 (H1):** 차이가 있다 (증명하고 싶은 가설)

Teacher's Note

👨‍⚖️ 1종 오류 vs 2종 오류

1종 오류 (판매자 오류): 귀무가설이 참인데 기각.
정상 제품인데 불량인 줄 알고 버림 ➡ 판매자 손해 😭.
유의수준(α)과 직결.

2종 오류 (소비자 오류): 귀무가설이 거짓인데 채택.
불량 제품인데 정상인 줄 알고 삼 ➡ 소비자 분노 😡.

가설검정 실전 6단계 프로세스

귀무/대립가설 설정 (예: 공장 불량률은 1.7%이다)

↓

양측/단측 확인 (대립가설이 '같지 않다' ➡ 양측검정)

↓

표본 수 확인 (한 개의 모집단 ➡ 일표본)

↓

검정통계량 계산 (모분산 알면 Z-검정, 모르면 t-검정)

↓

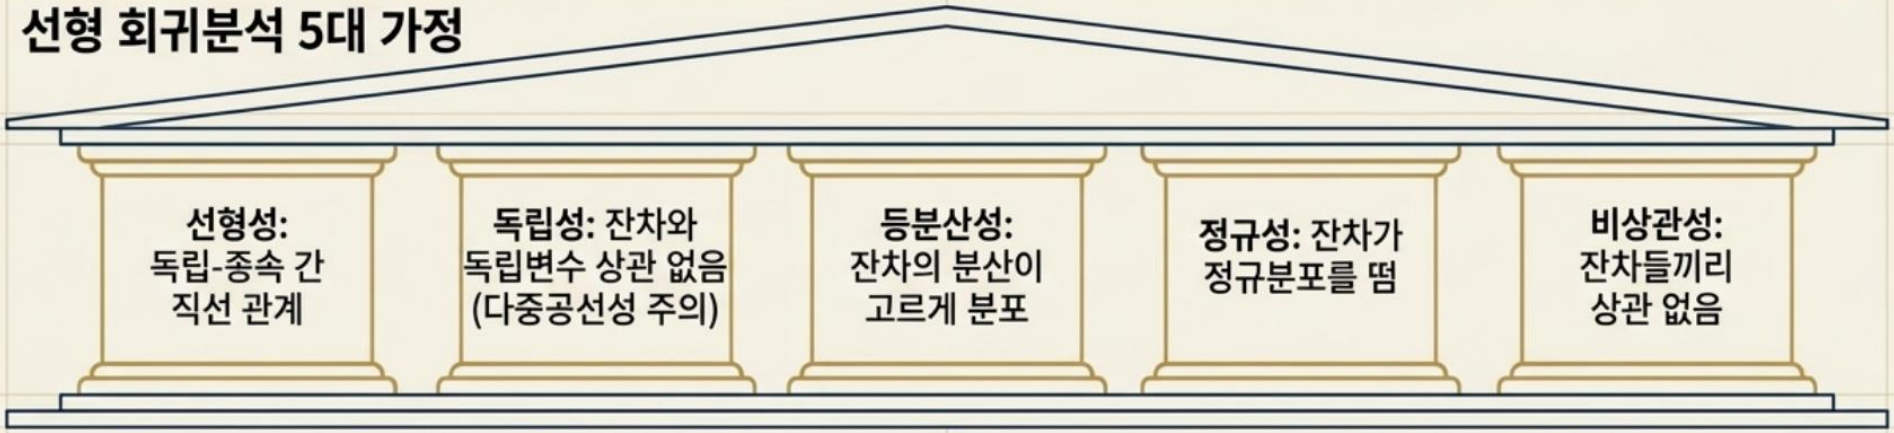
기각역 비교 판단 (검정통계량이 기각역 안에 들어가면 H_0 기각!)

↓

t검정 시 **단일/대응/독립 표본 확인**

선형 회귀분석의 기초와 기초와 모형 평가

선형 회귀분석 5대 가정



회귀모형 평가 및 R 결과 해석

- 종속변수 height / 득립변수 age, no_siblings

```
call:
lm(formula = height ~ age + no_siblings, data = ageandheight)

Residuals:
     Min       1Q   Median       3Q      Max
-0.28029 -0.22490 -0.02219  0.14418  0.48350

Coefficients:
             Estimate Std. Error t value Pr(>|t|)
(Intercept) 64.95872    0.55752 116.515 1.28e-15 ***
age          0.63516    0.02254  28.180 4.34e-10 ***
no_siblings -0.01137    0.05893  -0.193    0.851
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.2693 on 9 degrees of freedom
Multiple R-squared:  0.9888,    Adjusted R-squared:  0.9863
F-statistic: 397.7 on 2 and 9 DF,  p-value: 1.638e-09
```

R-square (결정계수): 0~1 사이, 1에 가까울수록 모델 설명력이 높음.

F통계량 & P-value: '모형 전체'가 유의미한가? (P < 0.05 이면 모형 통과).

t통계량 & P-value: '각 회귀계수(변수)'가 유의미한가? (P < 0.05 이면 변수 통과).

변수 선택법: 전진(추가), 후진(제거), 단계별. 벌점(AIC, BIC)은 낮을수록 좋음.

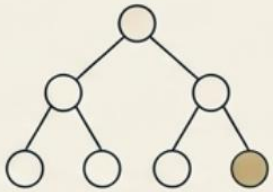
분류(지도학습)와 군집화(비지도학습) 알고리즘

주요 분류 알고리즘 (정답 있음)



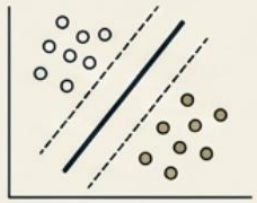
로지스틱 회귀

종속변수가 범주형일 때(예/아니오).
'오즈(Odds)'와 '로짓 변환'을 통해
확률 예측.



의사결정나무

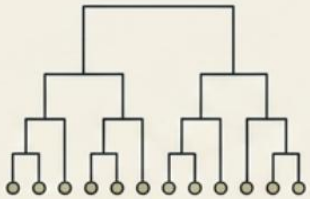
스무고개처럼 가지치기.
분류(지니, 엔트로피), 회귀(분산 감소).
과적합 방지 위해 '가지치기(Pruning)' 필수.



SVM (서포트 벡터 머신)

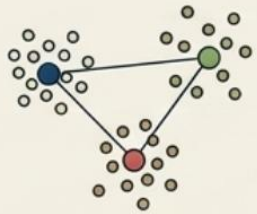
데이터를 가장 넓게 가르는 초평면
(Hyperplane)과 마진(Margin) 최대화.
하드마진 vs 소프트마진.

주요 군집화 알고리즘 (정답 없음)



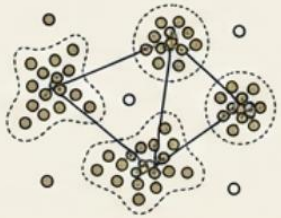
계층적 군집분석

덴드로그램 활용.
데이터 간 거리에 따라 순차적으로
묶기(최단, 최장, 와드 등).



K-평균 (K-Means)

지정된 K개의 중심점을
이동하며 군집화.
이상치에 취약함.



DBSCAN

밀도 기반 연결.
군집 수를 미리 지정할 필요 없으며
이상치(노이즈)에 매우 강함.

인공신경망 딥러닝과 과적합(Overfitting) 방지

딥러닝 3대장 구조 이해

DNN (심층 신경망)

은닉층이 2개 이상인 다층 퍼셉트론.
가장 기본적인 인공신경망 구조.

CNN (합성곱 신경망)

'이미지' 패턴 인식의 왕.
자율주행, 얼굴인식에 주로 활용.

RNN (순환 신경망)

'순서(시계열)'가 있는 데이터. 텍스트, 음성.
장기의존성 문제 해결을 위해 LSTM 사용.

과적합(Overfitting) 방지 기법

👩‍🏫 [Teacher's Note]: 과대적합은 시험 족보만 달달 외워서 기출문제는 100점인데, 실전 응용문제는 빵점 맞는 상태입니다. 모델의 힘을 일부러 빼야 합니다!

L1 (라쏘 규제):

절대값(맨하튼 거리).
중요도 없는 변수 가중치를
아예 0으로 삭제.

L2 (릿지 규제):

제곱(유클리드 거리).
변수의 영향을 0에 가깝게
줄여 크기 제한.

드롭아웃 (Dropout)

학습시 신경 시라:
학습 시 신경망의 퍼셉트론
일부를 무작위로 꺼버림.

조기종료 (Early Stopping)

검증 데이터 오차가 커지기
전에(과적합 되기 전)
학습 강제 중단.

앙상블 기법과 시계열 분석 기초

앙상블 (Ensemble) 기법

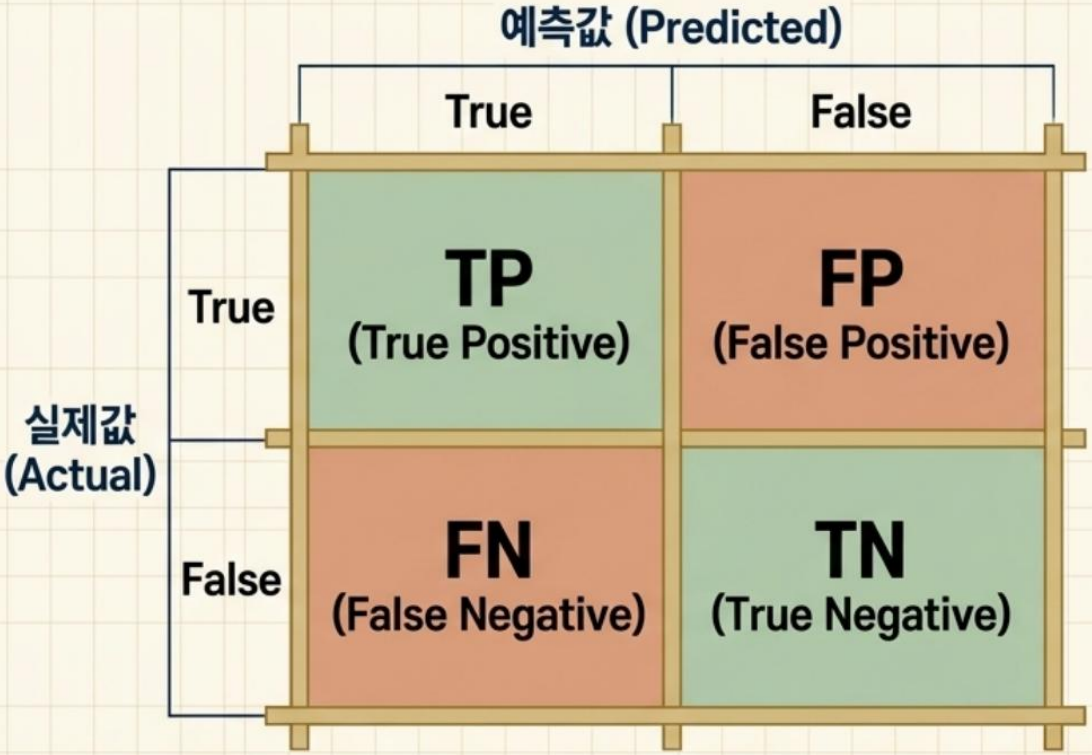
👩‍🏫 [Teacher's Note]: 혼자보다 여러 전문가의 의견을 합치는 게 낫다! 전체적인 '분산'을 감소시켜 성능을 향상시킵니다.

- **보팅 (Voting)** 투표를 통한 다수결 방식.
- **배깅 (Bagging)** 복원 추출(붓스트랩)로 병렬 학습 후 결과 결합.
- **랜덤 포레스트** 배깅 + 의사결정나무 숲. 성능이 우수하고 이상치에 강함.
- **부스팅 (Boosting)** 앞 모델이 틀린 문제에 가중치를 부여해 순차적 집중 학습. 이상치에 민감, 병렬 불가.

시계열 분석의 이해

- **정상성 (Stationarity)**
  - 시간에 상관없이 평균과 분산이 일정한 상태.
  - 비정상 시계열은 '차분'을 통해 정상화.
- **ARIMA 모형**
  - AR (자기회귀): 과거 값이 미래를 결정.
  - MA (이동평균): 오차들의 선형결합.
  - I (누적): 차분 적용 횟수.
- **분해 시계열 4요소**
  - 추세(Trend): 장기적 증감.
  - 계절(Seasonality): 고정된 특정 주기.
  - 순환(Cycle): 중장기 경제 사이클.
  - 불규칙(Irregular): 설명 불가한 랜덤 오차.

분석모형 평가 1: 오분류표 (Confusion Matrix) 완벽 해부



- 정확도 (Accuracy): 전체 중 맞춘 비율
  = (TP+TN) / (TP+FP+FN+TN)

- 재현율 (Recall) = 민감도: 실제 True 중 맞춘 비율 = TP / (TP+FN).
  (예: 실제 암환자 중 암이라고 진단한 비율)

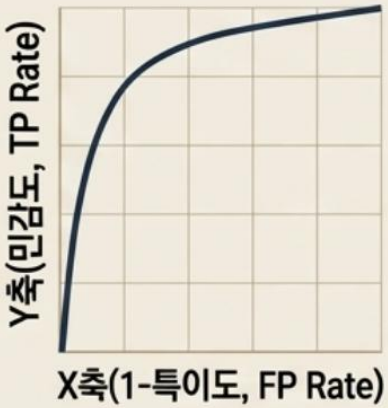
- 정밀도 (Precision) : True라고 예측한 것 중 진짜 True 비율 = TP / (TP+FP).
  (예: 암이라고 진단한 사람 중 진짜 암환자 비율)

- 특이도 (Specificity): 실제 False 중 맞춘 비율
  = TN / (FP+TN).
  (예: 정상인 중 정상이라고 진단한 비율)

[F1 Score]: 정밀도와 재현율의 '조화평균'. 불균형 데이터 평가 시 최고의 지표.
정밀도와 재현율은 서로 Trade-off(반비례) 관계입니다.

분석모형 평가 2: 곡선 도표 평가와 교차 검증

곡선 및 도표 평가



ROC 커브

그래프가 좌상단으로 굽을수록, 즉 곡선 아래 면적(AUC)이 1에 가까울수록 성능이 우수함.

이익 도표 (Lift Chart)

분류 모델의 성능을 랜덤 모델과 비교. 각 등급별로 예측이 얼마나 향상되었는지 파악하며 불균형 데이터 평가에 유용함.

교차 검증 (Cross Validation)

목적: 과적합 방지 및 데이터 부족 문제 해결

홀드아웃 (Hold-out)

- 전체 데이터를 훈련용(50%), 검증용(30%), 평가용(20%)으로 단순 분할.

K-Fold 교차검증

- 데이터를 K개로 쪼개서 (K-1)개로 학습하고 1개로 평가하는 과정을 K번 반복.

LOOCV

- 단 1개의 데이터만 평가용으로 남기고 나머지 몽땅 학습에 사용하는 극한의 방식.

붓스트랩 (Bootstrap)

- 복원 추출 방식. 한 번도 뽑히지 않는 데이터 (OOB - Out of Bag)가 약 36.8% 발생함.

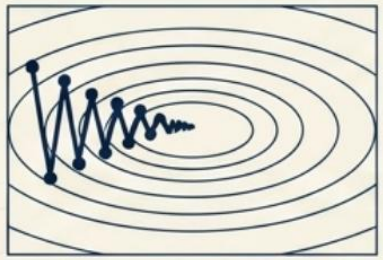
모델 튜닝: 하이퍼파라미터와 경사하강법 옵티마이저

하이퍼파라미터 (Hyperparameter) 튜닝

사용자가 직접 설정하는 통제 값 (예: 배치 사이즈, 학습률, 에포크).
튜닝 기법으로는 그리드 서치(모든 조합), 랜덤 서치, 베이지안 최적화(이전 결과 반영)가 있습니다.

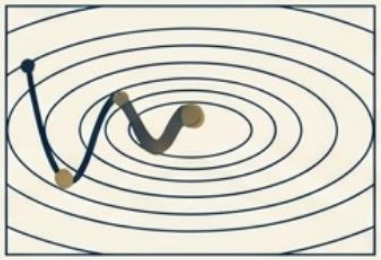
경사하강법 옵티마이저 진화 과정

SGD (확률적 경사하강법)



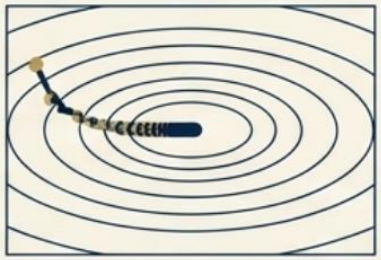
가장 가파른 기울기를 따라
지그재그로 내려감.

Momentum (모멘텀)



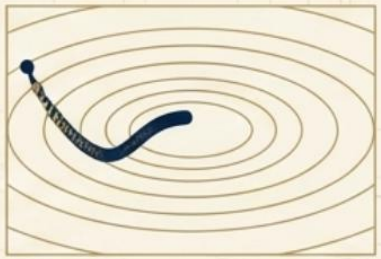
SGD + 관성(속도).
공이 그릇 바닥을 구르듯
가속이 붙어 지그재그가 덜함.

AdaGrad (아다그라드)



보폭(학습률) 조절.
처음엔 크게, 최적점 가까워지면
조금씩 세밀하게 이동.

Adam (아담)



💡 모멘텀 + AdaGrad.
관성과 보폭 조절을 합친 끝판왕.
좌우 흔들림이 가장 적음.

최종 맵핑: 자료 형태에 따른 분석 기법 선택 흐름도

변수 형태 (독립변수 ➔ 종속변수)	분석 알고리즘 (예시)
독립변수(연속형) ➔ 종속변수(연속형)	선형 회귀분석 (예: 키로 몸무게 예측)
독립변수(연속형) ➔ 종속변수(범주형)	로지스틱 회귀분석 (예: 점수로 합격 여부 예측)
독립변수(범주형) ➔ 종속변수(연속형)	분산분석 ANOVA (예: 성별에 따른 수학점수 차이)
독립변수(범주형) ➔ 종속변수(범주형)	카이제곱 검정, 교차분석 (예: 성별과 흡연 유무의 독립성)
시간(연속형) ➔ 종속변수(연속형)	시계열 분석 ARIMA (예: 매출, 주가 예측)
종속변수 없음 (비지도 학습)	주성분분석(PCA), 군집분석, 연관분석

시험장 직전 10초 최종 점검

최종 요약 체크리스트

- ☑ 데이터 3법 핵심 = '가명정보' (통계/연구 목적 동의 없이 활용!)
- ☑ 분석과제 우선순위 = 시급성(비즈니스 밸류), 난이도(3V 투자비용)
- ☑ 1종 오류 = 귀무가설이 맞는데 기각함 (판매자의 억울한 손해)
- ☑ PCA(주성분분석) = 정보(분산) 보존을 위해 선형결합으로 새로운 축 생성
- ☑ 재현율(Recall) = 실제 True 중 맞춘 것 (실제 암환자 찾아내기)
- ☑ 과적합 방지 기법 = L1/L2 규제, 드롭아웃, 조기종료 적용

빅데이터 분석의 뼈대부터 디테일까지
완벽하게 설계하셨습니다.

데이터 설계자의 청사진이
머릿속에 완성되었습니다.

여러분의 압도적인 합격을 기원합니다!

