BIG DATA ANALYSIS ENGINEER · 01

빅데이터분석기사 필기 핵심 요약본

4과목 핵심 개념 · 비교표 · 공식 · 함정 · 80문제 해설

자료 조사·업데이트 기준일 2026-07-17
자료 제작자 상원.zip | 블로그명 rongleader | 이메일 rongleader@naver.com

비공식 학습자료 · 개인 학습용

이 자료를 가장 효율적으로 쓰는 법

[최우선] 이 책은 기본서를 처음부터 대신 읽는 책이 아니라, 시험에 필요한 판단 기준을 빠르게 세우고 기출·복원 문제의 오답을 줄이는 책이다. 1회독은 개념 구분, 2회독은 공식과 함정, 3회독은 문제만 풀어본다.

공식 시험 구성과 합격 기준

구분	공식 확인 내용	수험 전략
필기	4과목, 과목별 20문항, 총 80문항, 120분	한 문항에 오래 매달리지 말고 1차 풀이 후 계산·애매한 문제로 돌아온다.
합격	전 과목 평균 60점 이상이며 각 과목 40점 미만이면 과락	평균만 맞추는 전략은 위험하다. 과목당 최소 8문항보다 여유 있게 확보한다.
실기 연계	필기 합격 후 응시자격 심사를 통과해야 실기 응시 가능	필기에서 전처리·통계·모형·평가지표를 제대로 잡으면 실기 준비 시간이 줄어든다.
시행	필기·실기 연 2회 정기 시행	세부 일정은 매 회차 공식 공지를 다시 확인한다.

[주의] 2026년 제13회 공식 일정은 필기 9월 5일, 실기 11월 28일로 안내되어 있다. 일정은 변경될 수 있으므로 접수 전 데이터자격시험 공지를 다시 확인한다.

최근 경향을 반영한 학습 원칙

- [필수] 공식 세부항목을 공부 범위의 경계로 삼는다. 복원 문제에 없었다는 이유만으로 공식 범위를 버리지 않는다.
- [최근 복원 문제 기준] 제12회 필기 후기에는 낯선 용어와 세부 통계 개념이 늘어 기출 암기만으로 대응하기 어려웠다는 반응이 반복된다.
- [최우선] 2과목의 전처리·추론통계, 3과목의 분석기법, 4과목의 평가 지표는 서로 연결해 공부한다.
- [암기 필요] 1과목의 절차·방법론·법제도는 순서와 적용 목적을 묶어서 외운다.
- [주의] '항상', '반드시', '오직', '모든'처럼 범위를 과장하는 선택지는 먼저 의심한다.

4과목 우선순위 지도

과목	최우선 학습	반드시 이해	암기 필요	시간 여유가 있으면
분석 기획	분석 방법론, 개인정보·가명정보, 품질·수집·저장	플랫폼 구조, 문제 정의	조직 역할, 절차 순서	세부 산업 사례
탐색	결측·이상치, 변수 처리, 추론통계	표본분포, 상관, 차원축소	분포 특징, 표본추출	시공간·비정형 탐색 세부
모델링	회귀·로지스틱·나무·군집·앙상블	SVM·연관·신경망	알고리즘별 장단점	베이지안·딥러닝 세부 구조
결과 해석	분류·회귀 평가지표, 교차검증, 과대적합	모형 진단·선정·모니터링	시각화 선택	세부 배포 운영 사례

목차

이 자료를 가장 효율적으로 쓰는 법 . . . 2

공식 시험 구성과 합격 기준 . . . 2

최근 경향을 반영한 학습 원칙 . . . 2

4과목 우선순위 지도 . . . 2

목차 . . . 3

1과목 빅데이터 분석 기획 . . . 5

학습 목표와 중요도 . . . 5

핵심 개념 압축 . . . 5

1과목 빈출 함정 12 . . . 8

1과목 핵심 요약 . . . 8

2과목 빅데이터 탐색 . . . 9

학습 목표와 중요도 . . . 9

핵심 개념 압축 . . . 9

2과목 빈출 함정 14 . . . 12

2과목 핵심 요약 . . . 12

3과목 빅데이터 모델링 . . . 13

학습 목표와 중요도 . . . 13

핵심 개념 압축 . . . 13

3과목 빈출 함정 15 . . . 16

3과목 핵심 요약 . . . 16

4과목 빅데이터 결과 해석 . . . 16

학습 목표와 중요도 . . . 16

핵심 개념 압축 . . . 17

4과목 빈출 함정 14 . . . 19

4과목 핵심 요약 . . . 19

공식·계산·비교 최종 정리 . . . 21

기초 통계 공식 . . . 21

확률 공식 . . . 21

추정·검정 공식 . . . 21

회귀·분류 공식 . . . 21

혼동행렬 계산 예제 . . . 22

나무·거리·군집·연관 공식 . . . 22

핵심 비교표 . . . 22

통계 검정 선택 기준 . . . 24

문제 문장 의사결정표 . . . 24

t검정 선택 한 줄 규칙 . . . 24

ANOVA 해석 . . . 24
검정 결론 문장 템플릿 . . . 24
과목별 미니 테스트 40문제 . . . 25
1과목 미니 테스트 . . . 25
2과목 미니 테스트 . . . 26
3과목 미니 테스트 . . . 28
4과목 미니 테스트 . . . 30
종합 모의문제 40문제 . . . 32
문제 . . . 32
정답 및 상세 해설 . . . 39
1과목 미니 테스트 해설 . . . 39
2과목 미니 테스트 해설 . . . 40
3과목 미니 테스트 해설 . . . 40
4과목 미니 테스트 해설 . . . 41
종합 모의문제 해설 . . . 42
참고 출처와 배포 안내 . . . 46
자료 조사 기준 . . . 46
주요 참고 링크 . . . 46
배포용 면책문구 . . . 46

1과목 빅데이터 분석 기획

학습 목표와 중요도

단원	중요도	이유
분석 문제 정의·방법론	최우선 학습	절차 순서, 산출물, 방법론 비교를 섞은 문제가 반복되기 쉽다.
개인정보·가명정보	최우선 학습	법적 허용 목적과 개인정보 해당 여부를 반대로 내는 함정이 많다.
수집·변환·품질·비식별화	반드시 이해	데이터 확보 계획과 실제 처리 단계가 연결되어 출제된다.
플랫폼·저장 기술	반드시 이해	HDFS·MapReduce·Spark·NoSQL의 역할을 구분해야 한다.
조직·인력·데이터 산업	암기 필요	역할과 조직 구조의 장단점을 짧게 묻기 좋다.
세부 산업 활용 사례	시간 여유가 있으면	공식 범위지만 핵심 원리보다 우선순위는 낮다.

핵심 개념 압축

DIKW 피라미드

한 줄 정의: 데이터가 맥락과 판단을 거쳐 지혜로 발전하는 구조다.

- 반드시 알아야 할 핵심: Data는 관측 사실, Information은 의미 있게 가공한 결과, Knowledge는 규칙·패턴, Wisdom은 목적에 맞는 판단이다.
- 출제 방식: 사례를 주고 어느 단계인지 묻거나 순서를 바꾼다.
- 비슷한 개념과 차이: 단순 집계는 정보일 수 있지만 의사결정 원칙까지 일반화하면 지식에 가깝다.
- [자주 틀림] 원시 숫자에 단위를 붙였다는 이유만으로 지식이 되는 것은 아니다.
- 기억법: 데-정-지-혜 = 사실-맥락-규칙-판단.

정형·반정형·비정형 데이터

구분	구조	대표 예	함정
정형	고정 스키마와 행·열	관계형 DB 테이블, CSV	CSV는 텍스트 파일이지만 표 구조가 있으면 정형으로 본다.
반정형	자체 태그·키로 구조 표현	JSON, XML, 로그	스키마가 완전히 없다는 설명은 틀리다.
비정형	고정된 구조가 약함	이미지, 음성, 자연어 문서	분석할 수 없다는 뜻이 아니다.

빅데이터의 특징 5V

한 줄 정의: 규모·속도·다양성에 진실성과 가치까지 더한 특성이다.

- Volume: 데이터의 양, Velocity: 생성·처리 속도, Variety: 형태 다양성, Veracity: 신뢰성, Value: 활용 가치.
- 출제 방식: 사례와 V를 연결하거나 유사한 용어를 섞는다.
- [함정] Visualization은 실무에서 중요하지만 고전적 5V의 고정 구성으로 단정하지 않는다.
- 기억법: 양이 빠르게 다양하게 들어와도, 믿을 수 있고 가치가 있어야 한다.

데이터 조직 구조

구조	핵심	장점	약점
집중형	독립 분석 조직에 인력 집중	전문성·표준화	현업 업무 이해와 소통이 약해질 수 있음

구조	핵심	장점	약점
기능형	현업 부서가 직접 분석	업무 밀착	중복 투자·전사 표준 약화
분산형	분석 인력을 현업에 배치하고 중앙이 조정	전문성과 현업 이해의 균형	역할·책임 조정이 복잡

분석 과제 발굴: 하향식과 상향식

- 하향식: 경영 문제를 먼저 정의하고 원인을 구조화해 분석 과제로 좁힌다. 문제 주도 방식이다.
- 상향식: 보유 데이터 탐색과 프로토타이핑으로 의미 있는 패턴·기회를 발견한다. 데이터 주도 방식이다.
- [자주 틀림] 둘 중 하나만 고집하지 않는다. 실제 과제는 반복적으로 결합한다.

분석 방법론

방법론	핵심 순서	구별 포인트
CRISP-DM	업무 이해 → 데이터 이해 → 데이터 준비 → 모델링 → 평가 → 전개	업무 이해로 시작하며 단계 간 반복이 가능
KDD	데이터 선택 → 전처리 → 변환 → 데이터마이닝 → 해석·평가	데이터 선택과 변환을 명시적으로 구분
SEMMA	Sample → Explore → Modify → Model → Assess	SAS에서 제시, 비즈니스 이해 단계가 명시되지 않음

[필수 암기] CRISP-DM은 '업-데-준-모-평-전', SEMMA는 영문 첫 글자 그대로 외운다. 절차는 직선이 아니라 필요하면 이전 단계로 돌아간다.

분석 과제 우선순위

- 전략적 중요도·실행 용이성·시급성·투자 대비 효과를 함께 본다.
- 난이도가 낮다는 이유만으로 가치가 낮은 과제를 먼저 수행하는 것은 적절하지 않다.
- Quick Win은 가치와 실행 가능성이 모두 높은 과제다.

데이터 수집 방식

방식	적합한 상황	주의점
로그·센서 수집	시스템·IoT가 지속 생성	시간 동기화, 중복, 누락
크롤링	공개 웹 문서 수집	이용약관·저작권·robots·개인정보 확인
Open API	제공자가 규격화한 데이터	호출 제한, 인증, 버전 변경
설문·인터뷰	태도·동기 등 직접 관측 어려운 정보	표본편향·응답편향
DB 연계	내부 업무 데이터	키 정합성·권한·스키마 변경

ETL과 ELT

구분	순서	적합한 환경	핵심 차이
ETL	추출 → 변환 → 적재	전통적 DW, 엄격한 사전 품질	저장 전 변환
ELT	추출 → 적재 → 변환	데이터 레이크·대규모 분산 환경	원본 적재 후 필요할 때 변환

데이터 품질

- 정확성: 실제 값을 올바르게 표현하는가.
- 완전성: 필요한 값이 빠짐없이 존재하는가.
- 일관성: 시스템·테이블 간 정의와 값이 충돌하지 않는가.
- 유효성: 형식·범위·업무 규칙을 지키는가.

- 적시성: 필요한 시점에 최신 상태로 제공되는가.
- 유일성: 동일 실체가 중복되지 않는가.
- [함정] 값이 형식 규칙을 지켜도 실제와 다르면 유효성은 높고 정확성은 낮을 수 있다.

빅데이터 플랫폼 핵심 역할

기술	핵심 역할	잘못된 설명 구별
HDFS	큰 파일을 블록으로 나눠 여러 노드에 복제 저장	저지연 랜덤 수정에 최적이라는 설명은 틀림
MapReduce	Map과 Reduce 단계의 배치 분산 처리	반복 분석에서 항상 Spark보다 빠르다는 설명은 틀림
Spark	메모리 중심의 범용 분산 처리	저장 시스템 자체로만 보는 설명은 부정확
Kafka	분산 이벤트 스트리밍·메시지 전달	관계형 질의 엔진으로 보는 설명은 틀림
NoSQL	유연한 스키마와 수평 확장	모든 NoSQL이 트랜잭션을 전혀 지원하지 않는다는 단정은 틀림

NoSQL 유형

유형	데이터 모습	대표 활용
Key-Value	키와 값	캐시, 세션
Document	JSON 유사 문서	콘텐츠·상품 카탈로그
Column-family	열 묶음 중심	대규모 로그·시계열
Graph	노드와 관계	추천·사기 탐지·관계망

CAP 정리

분산 시스템은 네트워크 분할(P)이 발생한 상황에서 일관성(C)과 가용성(A)을 동시에 완벽히 보장하기 어렵다는 관점이다. 실무 시스템은 요구 수준에 따라 절충한다.

> [자주 틀림] CAP는 평상시 무조건 세 특성 중 정확히 두 개만 선택한다는 단순 규칙이 아니다. 핵심은 '네트워크 분할 상황의 절충'이다.

인공지능·머신러닝·딥러닝

개념	관계	핵심
인공지능	가장 넓은 범위	인간의 지능적 과업을 수행하는 기술 전체
머신러닝	인공지능의 일부	데이터에서 규칙을 학습
딥러닝	머신러닝의 일부	다층 신경망으로 표현을 학습

개인정보·가명정보·익명정보

구분	개인정보 해당	복원·식별 가능성	활용 핵심
개인정보	해당	개인을 알아볼 수 있음	법적 처리 근거 필요
가명정보	해당	추가정보 없이는 특정인 식별 어려움	통계작성·과학적 연구·공익적 기록보존 등 법정 목적에서 동의 없이 처리 가능
익명정보	합리적으로 개인을 알아볼 수 없음	복원이 사실상 불가능한 수준	개인정보 보호법상 개인정보가 아님

> [주의] 2026년 현행 안내 기준으로 가명정보는 여전히 개인정보다. 서로 다른 개인정보처리자 간 가명정보 결합은 지정된 전문기관을 통한 절차가 적용될 수 있다. 법제도 문항은 시험 직전 최신 공식 안내를 다시 확인한다.

비식별화 기법

기법	설명	예
가명처리	식별자를 다른 값으로 대체	이름 → 임의 번호
총계처리	개별값 대신 합계·평균 등 제공	연령 → 지역 평균연령
데이터 삭제	식별 위험 항목 제거	상세주소 삭제
범주화	세부값을 구간·범주로 바꿈	27세 → 20대
데이터 마스킹	일부 문자를 가림	010-****-1234

1과목 빈출 함정 12

틀리기 쉬운 설명	왜 틀렸나·올바른 개념	구별법
반정형 데이터에는 구조가 없다.	태그·키 등 자체 구조가 있다.	JSON·XML이면 반정형을 먼저 생각한다.
CRISP-DM은 일방향 순차 절차다.	단계 간 반복과 회귀가 가능하다.	‘반드시 이전 단계로 못 돌아간다’면 오답.
SEMMA는 업무 이해로 시작한다.	Sample로 시작하며 업무 이해가 명시 단계가 아니다.	S-E-M-M-A를 그대로 확인.
ELT는 적재 전에 변환한다.	적재 후 변환한다.	가운데 L의 위치를 본다.
HDFS는 작은 파일의 잦은 수정에 최적이다.	큰 파일의 순차 처리에 적합하다.	‘저지연 랜덤 수정’이면 의심.
Spark는 데이터 저장소 그 자체다.	범용 분산 처리 엔진으로 보는 것이 핵심이다.	처리와 저장 역할을 분리.
가명정보는 개인정보가 아니다.	가명정보도 개인정보다.	‘추가정보 없이 식별 어려움’일 뿐.
가명정보는 어떤 목적이든 동의 없이 쓸 수 있다.	법정 목적과 보호조치를 지켜야 한다.	목적 제한이 사라지는 선택지는 오답.
익명정보는 추가정보로 쉽게 복원할 수 있다.	합리적으로 개인을 알아볼 수 없어야 한다.	복원 가능하면 가명정보 가능성.
데이터 정확성과 유효성은 같다.	실제값 부합과 형식·규칙 준수는 다르다.	실제 vs 규칙을 구별.
하향식만이 올바른 과제 발굴이다.	상향식과 반복 결합 가능하다.	‘오직 한 방식’ 표현을 경계.
CAP는 언제나 세 특성 중 두 개만 선택한다.	분할 발생 시 C와 A 사이 절충이 핵심이다.	P 상황이 빠진 단정은 부정확.

1과목 핵심 요약

- [필수 암기] CRISP-DM: 업무 이해 → 데이터 이해 → 데이터 준비 → 모델링 → 평가 → 전개.
- [필수] 가명정보도 개인정보이며 활용 목적과 보호조치가 제한된다.
- [빈출] 품질 차원은 실제 부합, 누락, 충돌, 규칙, 시점, 중복을 각각 구분한다.
- [반드시 이해] HDFS는 저장, Spark·MapReduce는 처리, Kafka는 스트림 전달이다.

2과목 빅데이터 탐색

학습 목표와 중요도

단원	중요도	이유
결측·이상치 처리	최우선 학습	처리 방법이 통계량과 모델 편향에 미치는 영향을 묻기 쉽다.
변수 선택·변환·불균형	최우선 학습	정규화·표준화·차원축소·샘플링을 자주 혼동한다.
추론통계·가설검정	최우선 학습	공식 계산과 검정 해석이 3·4과목 및 실기와 직접 연결된다.
확률분포·표본분포	반드시 이해	평균·분산·표준오차·중심극한정리의 관계가 핵심이다.
상관·다변량 탐색	반드시 이해	상관계수, PCA, 요인분석을 비교해야 한다.
시공간·비정형 탐색	시간 여유가 있으면	공식 범위이므로 기본 정의와 대표 특징은 확인한다.

핵심 개념 압축

결측 메커니즘

유형	의미	예시·판단
MCAR	결측 발생이 관측·미관측 값과 무관	설문지가 우연히 훼손됨
MAR	다른 관측 변수로 결측을 설명 가능	연령에 따라 소득 무응답률이 다름
MNAR	결측값 자체와 결측 발생이 관련	고소득일수록 소득 응답을 회피

- 단순 삭제는 MCAR이고 결측 비율이 작을 때 상대적으로 안전하다.
- 평균 대치는 분산과 변수 간 관계를 축소할 수 있다.
- 다중대치는 결측의 불확실성을 여러 대치 데이터로 반영한다.
- [함정] 결측이 많다고 무조건 행 삭제하면 표본편향과 정보 손실이 커진다.

이상치 탐지

방법	기준·아이디어	장점	주의
IQR	Q1-1.5×IQR 미만 또는 Q3+1.5×IQR 초과	분포 가정이 약함	다변량 관계는 반영 못함
Z-score	평균에서 표준편차 몇 배 떨어졌는지	간단함	평균·표준편차가 이상치에 민감
Mahalanobis	공분산을 반영한 다변량 거리	변수 상관 반영	공분산 추정과 스케일에 영향
LOF	주변 이웃보다 국소 밀도가 낮은 점	국소 이상치 탐지	이웃 수에 민감

[주의] 이상치는 입력 오류일 수도 있지만 실제로 중요한 희귀 사건일 수도 있다. 탐지와 제거는 같은 말이 아니다.

변수 선택과 변수 추출

구분	결과 변수	해석성	대표 방법
변수 선택	기존 변수 일부 유지	상대적으로 높음	Filter, Wrapper, Embedded
변수 추출	기존 변수 조합으로 새 변수 생성	낮아질 수 있음	PCA, 요인분석

- Filter: 모델 학습 전 통계 기준으로 선택. 빠르지만 모델 상호작용 반영이 약하다.
- Wrapper: 변수 조합마다 모델 성능을 평가. 계산량이 크고 과대적합 가능성이 있다.

- Embedded: 모델 학습 과정에서 선택. L1 규제, 나무 중요도 등이 예다.

정규화·표준화·로그변환

방법	식·결과	언제 유리	함정
Min-Max 정규화	(x-min)/(max-min), 보통 0~1	범위 통일	이상치에 민감
Z 표준화	(x-평균)/표준편차, 평균 0·표준편차 1	거리·경사 기반 모델	값 범위가 0~1로 제한되지 않음
Robust scaling	(x-중앙값)/IQR	이상치가 존재	평균 0·표준편차 1 보장 아님
로그변환	log(x) 또는 log1p(x)	오른쪽 꼬리·큰 값 영향 완화	0·음수 처리 확인

범주형 변수 처리

- 명목형: 순서가 없으므로 원-핫 인코딩이 기본이다.
- 순서형: 실제 순서를 보존하는 순서 인코딩을 고려한다.
- 레이블 인코딩 숫자는 거리나 크기를 의미하지 않을 수 있다.
- [자주 틀림] 명목형을 1, 2, 3으로 바꾸면 모델이 거짓 순서를 학습할 수 있다.

불균형 데이터 처리

방법	핵심	주의
언더샘플링	다수 클래스 감소	정보 손실
오버샘플링	소수 클래스 복제·증가	단순 복제는 과대적합 가능
SMOTE	소수 클래스 이웃 사이 합성	검증·테스트에 적용하면 누수
class_weight	손실에서 소수 클래스 가중	모델 지원 여부 확인

[필수] 샘플링·스케일링·대치는 학습 데이터에서 규칙을 학습하고 검증·테스트에 동일 규칙을 적용한다.

기초 통계량

- 평균은 모든 값의 영향을 받아 이상치에 민감하다.
- 중앙값은 순서 기반이라 이상치에 상대적으로 강건하다.
- 최빈값은 범주형에도 사용할 수 있다.
- 분산·표준편차는 산포, 사분위범위는 가운데 50%의 폭이다.
- 왜도: 분포 비대칭. 양의 왜도는 일반적으로 오른쪽 꼬리가 길다.
- 첨도: 꼬리와 뾰족함의 정도. 정의에 따라 정규분포 기준을 3 또는 초과첨도 0으로 둔다.

표본추출

방법	핵심	적합 상황
단순무작위	각 표본의 추출 기회가 동일	모집단 목록 확보
계통	임의 시작점 후 일정 간격	목록에 주기성이 없을 때
층화	동질적 층마다 표본 추출	소수 하위집단 보장·정밀도 향상
군집	이질적 군집 일부를 선택	넓은 지역·비용 절감

[자주 틀림] 층화 표본은 각 층 내부가 동질적이고 층 간 차이가 크도록, 군집 표본은 각 군집이 모집단의 축소판처럼 내부가 이질적인 것이 이상적이다.

주요 확률분포

분포	변수형	핵심
베르누이	이산	한 번의 성공/실패, 평균 p, 분산 p(1-p)
이항	이산	독립 베르누이 n회의 성공 횟수
포아송	이산	일정 구간의 사건 횟수, 평균=분산=λ
균등	연속·이산	가능한 값의 확률이 동일
정규	연속	평균 중심 대칭, 평균=중앙값=최빈값
지수	연속	포아송 과정의 사건 간 대기시간, 무기억성
t	연속	모분산 미지·소표본 평균 추론, 정규보다 꼬리가 두꺼움
카이제곱	연속	분산·적합도·독립성 검정, 0 이상·오른쪽 비대칭
F	연속	분산비·분산분석, 0 이상

조건부확률과 베이즈 정리

- P(A|B)=P(A∩B)/P(B).
- 독립이면 P(A∩B)=P(A)P(B)이고 P(A|B)=P(A)다.
- 베이즈: P(A|B)=P(B|A)P(A)/P(B).
- [함정] 배반은 동시에 일어날 수 없다는 뜻이고, 독립은 한 사건이 다른 사건의 확률에 영향을 주지 않는다는 뜻이다. 일반적으로 같은 말이 아니다.

표본분포·표준오차·중심극한정리

- 표본평균의 기댓값은 모집단 평균 μ다.
- 표본평균의 표준오차는 σ/√n이며 σ 미지이면 s/√n을 사용한다.
- 표본 수가 커지면 조건 아래 표본평균의 분포가 정규분포에 가까워진다.
- [자주 틀림] 표본 수가 커진다고 원자료 분포 자체가 정규분포로 변하는 것은 아니다.

추정과 가설검정

- 점추정: 모수를 하나의 값으로 추정.
- 구간추정: 신뢰수준과 함께 모수가 포함될 것으로 기대되는 구간을 제시.
- 귀무가설 H0: 기본 상태·차이 없음. 대립가설 H1: 연구자가 확인하려는 차이·효과.
- p-value: H0가 참이라는 가정 아래 관측값 이상으로 극단적인 결과가 나올 확률.
- p≤α이면 H0를 기각한다. p>α이면 '기각하지 못함'이지 H0가 참임을 증명한 것이 아니다.

실제·판정	H0 기각	H0 기각 못함
H0 참	제1종 오류 α	올바른 판정
H0 거짓	검정력 1-β	제2종 오류 β

상관분석

방법	측정 대상	조건·특징
Pearson	선형 관계	연속형, 이상치에 민감
Spearman	단조 관계	순위 기반, 비정규·순서형에 활용
Kendall	순위 일치	표본이 작거나 동률 고려에 유용

[필수] 상관은 인과를 보장하지 않는다. r=0은 선형 상관이 없다는 뜻이지 모든 비선형 관계가 없다는 뜻이 아니다.

PCA와 요인분석

구분	PCA	요인분석
목적	전체 분산을 최대한 보존해 차원축소	관측변수 뒤의 잠재요인 설명
변수 역할	모든 분산 활용	공통분산 중심
결과	서로 직교하는 주성분	해석 가능한 잠재요인
사용	압축·다중공선성 완화	설문 구성개념 탐색

시계열·공간·비정형 탐색 기초

- 시계열 구성: 추세, 계절, 순환, 불규칙.
- 정상성: 평균·분산·자기공분산 구조가 시간에 따라 안정적인 성질.
- 자기상관: 같은 변수의 시차 값 사이 상관.
- 공간 데이터는 위치와 공간적 자기상관을 함께 본다.
- 텍스트는 토큰화·정제·벡터화, 이미지는 픽셀·특징 추출이 기본 탐색 흐름이다.

2과목 빈출 함정 14

틀리기 쉬운 설명	올바른 개념	구별법
평균 대치는 원래 분산을 보존한다.	중앙으로 값이 몰려 분산이 줄 수 있다.	대치가 통계 구조에 미치는 영향 확인.
이상치는 발견 즉시 삭제한다.	오류·희귀사건·업무 맥락을 판단한다.	탐지와 처리 분리.
Z 표준화 결과는 항상 0~1이다.	평균 0, 표준편차 1이며 범위 제한이 없다.	0~1은 Min-Max.
PCA는 기존 변수 일부만 남긴다.	선형 결합의 새 성분을 만든다.	선택이 아니라 추출.
SMOTE를 전체 데이터에 먼저 적용한다.	학습 데이터에만 적용한다.	검증 정보가 들어가면 누수.
명목형 숫자 인코딩은 항상 안전하다.	거짓 순서를 줄 수 있다.	숫자 크기에 의미가 있는지 확인.
층화와 군집은 같은 추출이다.	층은 각 층에서, 군집은 일부 군집을 뽑는다.	내부 동질 vs 내부 이질.
배반 사건은 독립이다.	일반적으로 배반이면 한 사건 발생이 다른 사건 확률을 바꾼다.	교집합 0과 곱셈법칙을 비교.
표본 수가 커지면 원자료가 정규분포가 된다.	표본평균 분포가 정규에 가까워진다.	CLT의 대상을 확인.
p-value는 H0가 참일 확률이다.	H0 아래 데이터의 극단성 확률이다.	가설의 사후확률로 해석 금지.
p>0.05면 H0가 참이다.	기각할 증거가 부족한 것이다.	‘채택’보다 ‘기각 못함’.
r=0이면 두 변수는 완전히 무관하다.	비선형 관계는 존재할 수 있다.	선형 관계만 평가.
양의 왜도는 왼쪽 꼬리가 길다.	오른쪽 꼬리가 길다.	꼬리 방향으로 부호를 기억.
포아송 분포의 평균과 분산은 다르다.	둘 다 λ다.	포아송의 대표 성질.

2과목 핵심 요약

- [최우선] 전처리는 분석 목적과 결측·이상치 발생 메커니즘을 보고 결정한다.
- [필수 암기] 표준오차는 표준편차/√n, 표본이 커질수록 감소한다.
- [필수] p-value가 크면 H0를 증명하는 것이 아니라 기각하지 못한다.
- [빈출] PCA는 분산 보존 차원축소, 요인분석은 잠재요인 설명이다.

3과목 빅데이터 모델링

학습 목표와 중요도

단원	중요도	이유
회귀·로지스틱	최우선 학습	계수·가정·검정·예측을 모두 물을 수 있다.
의사결정나무·앙상블	최우선 학습	분할 기준과 배깅·부스팅 차이가 핵심이다.
군집·연관분석	최우선 학습	지표 계산과 알고리즘 특성 문제가 잘 나온다.
SVM·신경망	반드시 이해	초평면·커널·활성화·역전파를 구분한다.
시계열·다변량·비모수	반드시 이해	공식 범위이며 2과목과 연결된다.
딥러닝·비정형·베이지안	암기 필요	대표 구조와 사용 목적 중심으로 압축한다.

핵심 개념 압축

분석모형 구축 절차

문제·평가지표 정의 → 데이터 분할 → 전처리 → 후보모형 학습 → 검증·튜닝 → 최종모형 선정 → 테스트·해석.

> [필수] 테스트 데이터는 최종 일반화 성능 확인용이다. 반복 튜닝에 사용하면 사실상 검증 데이터가 되어 성능이 낙관적으로 편향된다.

지도·비지도·강화학습

유형	정답 레이블	목표	대표 예
지도학습	있음	입력에서 목표값 예측	분류·회귀
비지도학습	없음	구조·패턴 발견	군집·차원축소
강화학습	보상 신호	누적 보상을 최대화하는 행동 정책 학습	게임·제어

분류·회귀·군집

문제	출력	예	대표 지표
분류	범주·확률	이탈 여부	Accuracy, F1, ROC-AUC
회귀	연속값	매출액	MAE, RMSE, R^2
군집	유사 집단	고객 세분화	Silhouette, 군집 내 제곱합

선형회귀

- 회귀식: $y=\beta0+\beta1x1+\cdots+\beta pxp+\varepsilon$.
- 최소제곱법은 잔차 제곱합을 최소화한다.
- 주요 가정: 선형성, 오차 독립성, 등분산성, 오차 정규성. 설명변수 간 완전 다중공선성도 피한다.
- 계수 βj는 다른 변수를 고정할 때 xj가 1 증가함에 따른 y 평균 변화다.
- [함정] 유의한 계수는 인과효과를 자동으로 보장하지 않는다.

다중공선성

- 설명변수끼리 강하게 연관되어 계수의 분산과 해석 불안정성이 커지는 현상이다.

- VIF가 클수록 다른 설명변수로 해당 변수가 잘 설명된다. 절대 기준 하나만 기계적으로 적용하지 않는다.
- 대응: 변수 제거·결합, 규제, PCA, 더 많은 데이터, 업무 판단.

규제 회귀

방법	벌점	효과
Ridge	L2, 계수 제곱합	계수를 0에 가깝게 축소, 보통 정확히 0은 아님
Lasso	L1, 계수 절댓값합	일부 계수를 0으로 만들어 변수 선택 가능
Elastic Net	L1+L2	두 장점 절충

로지스틱 회귀

- logit(p)=log(p/(1-p))=β0+β1x1+⋯ 구조다.
- 계수 βj를 지수화한 exp(βj)는 xj 1단위 증가 시 오즈의 배수다.
- 확률은 0~1, 선형예측값과 로그오즈는 제한이 없다.
- [자주 틀림] exp(β)=1.2는 확률이 20%p 증가한다는 뜻이 아니라 오즈가 1.2배라는 뜻이다.

의사결정나무

- 분류는 지니·엔트로피, 회귀는 분산·제곱오차 감소 등을 분할 기준으로 쓴다.
- 해석이 쉽고 비선형·상호작용을 자동 포착하지만 깊은 나무는 과대적합하기 쉽다.
- 가지치기·최대 깊이·최소 잎 표본수로 복잡도를 제어한다.

엔트로피와 지니

- 엔트로피 $H=-\Sigma p_i \log2(p_i)$. 한 클래스만 있으면 0, 혼합이 클수록 증가한다.
- 지니 $G=1-\Sigma p_i^2$. 한 클래스만 있으면 0이다.
- 정보이득은 부모 불순도에서 자식의 가중 불순도를 뺀 값이다.

앙상블

방법	학습 방식	목적	대표
배깅	부트스트랩 표본에 병렬 학습	분산 감소	Random Forest
부스팅	이전 오차를 보완하며 순차 학습	편향 감소·정확도 향상	AdaBoost, Gradient Boosting
스태킹	여러 모델 예측을 메타모델이 결합	이질 모델 장점 결합	Base + Meta learner

랜덤포레스트

- 배깅에 매 분할마다 무작위 변수 후보 선택을 더해 나무 간 상관을 낮춘다.
- 개별 나무보다 해석은 어렵지만 분산이 낮고 안정적이다.
- OOB 표본은 각 나무의 부트스트랩에 뽑히지 않은 관측치로 내부 평가에 활용할 수 있다.

그래디언트 부스팅

이전 모델의 잔차 또는 손실의 음의 기울기를 다음 약한 학습기가 보완한다. 학습률이 작으면 보통 더 많은 트리가 필요하며, 깊이·트리 수와 함께 조절한다.

SVM

- 두 클래스 사이 마진을 최대화하는 초평면을 찾는다.
- C가 크면 오분류 벌점이 커져 훈련 데이터에 더 맞추고 마진이 좁아질 수 있다.
- 커널 트릭은 원공간에서 직접 고차원 좌표를 계산하지 않고 비선형 경계를 만든다.

- RBF의 gamma가 크면 한 점의 영향 범위가 좁아 복잡한 경계가 될 수 있다.

인공신경망

- 가중합 → 활성화함수 → 출력의 층을 쌓는다.
- 역전파는 손실의 기울기를 출력층에서 입력 방향으로 계산해 가중치를 갱신한다.
- ReLU=max(0,x)는 깊은 신경망에서 기울기 소실을 완화하지만 죽은 ReLU가 생길 수 있다.
- Sigmoid는 0~1 출력에 유리하나 깊은 은닉층에서 포화·기울기 소실 문제가 있다.
- Dropout은 학습 중 일부 뉴런을 무작위로 비활성화하는 규제다.

연관규칙

- 지지도 support(A→B)=P(A∩B).
- 신뢰도 confidence(A→B)=P(B|A)=P(A∩B)/P(A).
- 향상도 lift(A→B)=confidence/P(B). 1보다 크면 양의 연관, 1이면 독립 수준이다.
- [함정] A→B의 신뢰도와 B→A의 신뢰도는 일반적으로 다르지만 지지도는 같다.

군집 알고리즘 비교

알고리즘	핵심	장점	약점
K-means	중심까지 제곱거리 최소화	빠르고 단순	K 필요, 구형 군집·이상치·스케일에 민감
계층적 군집	병합·분할하며 덴드로그램	K를 나중에 결정 가능	대규모 데이터 계산 부담
DBSCAN	밀도 연결 영역을 군집화	임의 모양·잡음 탐지	eps·min_samples, 밀도 차이에 민감
Gaussian Mixture	확률적 혼합분포	소프트 군집	분포 가정·초기값에 민감

계층적 군집 연결법

연결법	군집 간 거리	경향
Single	가장 가까운 점	사슬 효과
Complete	가장 먼 점	조밀한 군집
Average	모든 쌍 거리 평균	절충
Ward	병합 시 군집 내 제곱합 증가 최소	구형·비슷한 크기 군집에 유리

시계열 모형

- AR(p): 과거 자신의 값으로 현재를 설명.
- MA(q): 과거 오차로 현재를 설명.
- ARMA: 정상 시계열에 AR과 MA 결합.
- ARIMA(p,d,q): d번 차분해 정상화한 뒤 ARMA 적용.
- 계절 ARIMA는 계절 차수 (P,D,Q)s를 추가한다.
- [함정] ACF·PACF 절단 패턴은 이상적 식별 힌트이며 실제 자료에서는 진단과 비교가 필요하다.

베이지안 기법

사전분포 prior와 우도 likelihood를 결합해 사후분포 posterior를 얻는다. 사후분포 ∝ 우도 × 사전분포다. MAP는 사후확률 최대, MLE는 우도 최대다.

딥러닝·비정형 대표 구조

구조	강점	대표 사용
CNN	지역 패턴·가중치 공유	이미지·격자 데이터
RNN/LSTM/GRU	순서·시계열 의존성	문장·시계열
Autoencoder	입력 복원으로 표현 학습	차원축소·이상탐지
Transformer	Attention 기반 병렬 문맥 처리	자연어·멀티모달

3과목 빈출 함정 15

틀리기 쉬운 설명	올바른 개념	구별법
테스트 데이터로 반복 튜닝한다.	검증으로 튜닝하고 테스트는 최종 평가에 쓴다.	평가 역할 분리.
회귀계수 유의성은 인과성을 보장한다.	연관성과 모형 조건 아래 효과다.	누락변수·설계 고려.
Ridge는 많은 계수를 정확히 0으로 만든다.	Lasso가 변수 선택에 더 직접적이다.	L1=0 가능, L2=축소.
로지스틱 계수는 확률 변화량이다.	로그오즈 변화량이다.	exp(β)는 오즈비.
깊은 나무일수록 일반화가 좋아진다.	과대적합 위험이 커진다.	복잡도 제어 확인.
랜덤포레스트는 부스팅이다.	배깅 기반이다.	병렬 vs 순차.
부스팅은 모든 모델을 독립 병렬 학습한다.	이전 오류를 순차 보완한다.	순차 의존성.
SVM의 C가 커지면 규제가 강해진다.	오분류 허용이 줄어 규제는 약해지는 방향이다.	벌점과 규제를 반대로 보지 않는다.
K-means는 범주형 원자료에 자연스럽다.	평균·거리 계산 가능한 수치형에 기본 적합하다.	중심이 평균인지 확인.
DBSCAN은 K를 먼저 정해야 한다.	eps와 min_samples를 정한다.	밀도 기반.
Single linkage는 사슬 효과를 줄인다.	사슬 효과가 생기기 쉽다.	최소거리 연결.
lift=1이면 강한 양의 연관이다.	독립 수준이다.	1 기준.
A→B와 B→A의 신뢰도는 같다.	분모가 달라 일반적으로 다르다.	조건부확률 방향.
ARIMA의 d는 이동평균 차수다.	차분 횟수다.	p=AR, d=차분, q=MA.
Dropout은 추론 시 무작위 뉴런 제거를 계속한다.	일반적으로 학습 시 적용하고 추론 시 비활성화한다.	학습·추론 구분.

3과목 핵심 요약

- [최우선] 데이터 분할의 역할과 누수 방지를 모든 모형보다 먼저 이해한다.
- [필수 암기] L1=Lasso=0 가능, L2=Ridge=부드러운 축소.
- [빈출] 배깅은 병렬·분산 감소, 부스팅은 순차·오류 보완.
- [필수] 로지스틱 회귀 exp(β)는 확률이 아니라 오즈의 배수다.

4과목 빅데이터 결과 해석

학습 목표와 중요도

단원	중요도	이유
분류·회귀 평가지표	최우선 학습	혼동행렬과 지표 계산·상황 선택이 핵심이다.
교차검증·모형 진단	최우선 학습	일반화 성능과 과대적합 판단에 직접 연결된다.
모수 유의성·적합도	반드시 이해	회귀·통계 결과 해석 문제가 나온다.
최적화·모형 융합·선정	반드시 이해	검증 절차와 모델 비교 원칙이 중요하다.
시각화	암기 필요	변수형·목적과 그래프를 연결한다.
전개·모니터링·리모델링	반드시 이해	데이터·개념 드리프트와 운영 지표를 구분한다.

핵심 개념 압축

혼동행렬과 분류 지표

지표	공식	질문으로 바꾸기	주의
Accuracy	(TP+TN)/전체	전체 중 몇 개를 맞혔나	불균형에 취약
Precision	TP/(TP+FP)	양성 예측 중 진짜 양성은	FP 비용이 클 때
Recall	TP/(TP+FN)	실제 양성 중 잡아낸 비율은	FN 비용이 클 때
Specificity	TN/(TN+FP)	실제 음성 중 걸러낸 비율은	음성 기준
F1	2PR/(P+R)	정밀도·재현율 균형은	산술평균이 아님

- 암 진단처럼 놓치면 큰 비용: Recall 중시.
- 스팸 차단처럼 정상 메일 오차가 큰 비용: Precision 중시.
- [함정] Positive는 '좋음'이 아니라 분석에서 관심 클래스를 뜻한다.

ROC-AUC와 PR-AUC

- ROC 곡선: 임계값에 따른 TPR(Recall)과 FPR의 관계.
- ROC-AUC: 임의의 양성이 임의의 음성보다 높은 점수를 받을 가능성에 대한 순위 성능 관점.
- PR 곡선: Precision과 Recall의 관계. 양성이 매우 희귀하면 PR-AUC가 더 민감할 수 있다.
- [주의] ROC-AUC에는 클래스 0/1 결과가 아니라 연속 점수·확률을 넣는다.

회귀 평가 지표

지표	핵심	장점	약점
MAE	|오차| 평균	해석 쉽고 이상치 영향이 RMSE보다 작음	큰 오차 강조가 약함
MSE	오차^2 평균	미분·최적화 용이	단위가 제곱
RMSE	$\sqrt{}$MSE	원래 단위, 큰 오차에 민감	이상치 영향 큼
MAPE	|오차/실제| 평균	비율 해석	실제값 0·작은 값 문제
RMSLE	로그 변환 후 RMSE	상대 오차·큰 값 영향 완화	음수 실제·예측값 불가
R^2	1-SSE/SST	설명된 변동 비율	테스트에서 음수 가능, 인과 아님

군집 평가

- Silhouette s=(b-a)/max(a,b). a는 같은 군집 평균거리, b는 가장 가까운 다른 군집 평균거리.
- 1에 가까울수록 응집과 분리가 좋고, 0 근처는 경계, 음수는 다른 군집이 더 가까울 수 있다.
- 군집 내 제곱합 WCSS는 K가 늘면 감소하므로 감소량이 꺾이는 Elbow를 참고한다.
- 외부 정답 레이블이 있으면 ARI, NMI 같은 외부 평가를 사용할 수 있다.

교차검증

방법	핵심	적합 상황
K-Fold	K개 폴드가 한 번씩 검증	일반 데이터
Stratified K-Fold	클래스 비율을 유지	분류·불균형
Group K-Fold	같은 그룹이 학습·검증에 섞이지 않음	환자·고객 반복 관측
Time Series Split	과거로 학습, 미래로 검증	시계열
LOOCV	한 개씩 검증	작은 표본, 계산량 큼

[자주 틀림] 시계열을 무작위 K-Fold로 나누면 미래 정보가 과거 학습에 들어갈 수 있다. 반복 측정 데이터는 같은 사람의 레코드가 양쪽에 섞이지 않게 그룹 분할을 고려한다.

과대적합·과소적합

상태	학습 오차	검증 오차	개선 방향
과대적합	매우 낮음	높음	규제, 단순화, 데이터 증가, 조기종료
과소적합	높음	높음	모형 복잡도·유용 변수 증가, 규제 완화

- Bias가 높으면 과소적합, Variance가 높으면 과대적합 경향이다.
- 학습곡선으로 데이터 양에 따른 학습·검증 성능 차이를 본다.

하이퍼파라미터 탐색

- Grid Search: 지정 조합을 전부 탐색. 공간이 작을 때 명확하다.
- Random Search: 분포에서 무작위 조합. 중요한 차원이 일부일 때 효율적일 수 있다.
- Bayesian Optimization: 이전 평가 결과를 이용해 유망한 조합을 선택한다.
- [필수] 탐색은 교차검증 내부에서 수행하고 최종 테스트는 마지막 한 번만 본다.

모형 유의성과 적합도

- 회귀 t검정: 개별 계수 $\beta j=0$인지.
- 회귀 F검정: 절편을 제외한 계수들이 동시에 0인지 등 모형 전체 유의성.
- R^2는 변수를 추가하면 감소하지 않으므로 조정 R^2는 변수 수에 벌점을 준다.
- AIC·BIC는 적합도와 복잡도를 절충하며 같은 데이터·목적의 후보 중 작을수록 선호한다.
- 잔차 진단은 선형성·등분산·정규성·독립성 위반 신호를 확인한다.

모델 해석

- 전역 해석: 모델 전체에서 변수 영향과 구조를 이해.
- 지역 해석: 특정 관측치의 예측 이유를 설명.
- Permutation Importance: 변수를 섞었을 때 성능 저하를 측정. 상관변수에서 중요도가 분산될 수 있다.
- PDP: 다른 변수를 평균화하며 특정 변수 변화에 따른 평균 예측 변화를 본다. 강한 상관에서 비현실 조합이 생길 수 있다.
- SHAP: 게임이론 기반 기여도. 기준 예측에서 각 변수가 얼마나 밀고 당겼는지 해석한다.

시각화 선택

목적	추천	피해야 할 혼동
범주별 크기 비교	막대그래프	범주에 히스토그램 사용
연속형 분포	히스토그램·밀도·상자그림	히스토그램 막대 간격을 범주막대처럼 해석
두 연속형 관계	산점도	인과로 단정

목적	추천	피해야 할 혼동
시간 추세	선그래프	시간 순서를 임의 정렬
구성비	누적막대·트리맵	범주가 많은 원그래프
지리 분포	등치지역도·점 지도	면적 큰 지역이 값도 크다고 착각

비즈니스 기여도와 모니터링

- 모델 지표와 비즈니스 지표를 분리한다. AUC 향상이 매출·비용 절감으로 자동 연결되지는 않는다.
- 데이터 드리프트: 입력 X의 분포 변화.
- 개념 드리프트: X와 y의 관계 변화.
- 성능 드리프트: 운영 성능 지표 저하로 관찰되는 현상.
- 모니터링은 입력 품질, 예측 분포, 실제 성능, 지연시간, 오류율, 공정성 등을 포함한다.
- 리모델링은 임계값 조정만으로 해결되지 않는 구조 변화가 확인될 때 고려한다.

4과목 빈출 함정 14

틀리기 쉬운 설명	올바른 개념	구별법
정확도가 높으면 불균형에서도 항상 우수하다.	다수 클래스만 맞혀도 높아질 수 있다.	혼동행렬과 F1·PR 확인.
Precision 분모는 실제 양성이다.	예측 양성 TP+FP다.	‘예측 중’이면 Precision.
Recall 분모는 예측 양성이다.	실제 양성 TP+FN이다.	‘실제 중’이면 Recall.
F1은 Precision과 Recall의 산술평균이다.	조화평균이다.	2PR/(P+R).
ROC-AUC에 클래스 예측값만 넣는 것이 최선이다.	연속 점수·확률을 사용한다.	임계값 전체 평가.
RMSE는 이상치 영향이 MAE보다 작다.	제곱 때문에 더 크다.	큰 오차 벌점.
R^2는 항상 0~1이다.	테스트·절편 없는 상황 등에서 음수 가능하다.	기준 평균모형보다 나쁠 수 있음.
K가 증가하면 WCSS가 증가한다.	감소하거나 동일하다.	군집 자유도 증가.
시계열에 무작위 교차검증이 항상 안전하다.	시간 순서를 보존한다.	미래 누수 확인.
Grid Search 결과를 테스트로 계속 비교한다.	검증으로 선택 후 테스트는 마지막 평가.	테스트 반복 사용 금지.
R^2가 큰 모형은 항상 변수 수와 무관하게 최선이다.	조정 R^2·검증성능·복잡도를 함께 본다.	훈련 적합과 일반화 구분.
AIC는 서로 다른 종속변수 모형도 절대 비교 가능하다.	같은 데이터·목적 후보 비교가 원칙이다.	비교 가능성 확인.
데이터 드리프트와 개념 드리프트는 같다.	입력 분포 변화와 관계 변화다.	P(X) vs P(y|X).
모델 성능이 좋으면 비즈니스 기여도도 자동으로 높다.	비용·수익·운영 제약을 별도 평가한다.	기술·사업 지표 분리.

4과목 핵심 요약

- [필수 암기] Precision은 예측 양성 기준, Recall은 실제 양성 기준.
- [최우선] 검증은 선택·튜닝, 테스트는 마지막 일반화 평가.
- [빈출] RMSE는 큰 오차에 민감, MAE는 상대적으로 강건하다.
- [필수] 데이터 드리프트=P(X) 변화, 개념 드리프트=P(y|X) 변화.

공식·계산·비교 최종 정리

기초 통계 공식

공식	기호·언제 사용	짧은 예	자주 하는 실수
평균 $\bar{x}=\Sigma x_i/n$	표본의 중심	2,4,6 → 4	가중평균과 혼동
모집단분산 $\sigma^2=\Sigma(x_i-\mu)^2/N$	모집단 전체 산포	2,4,6의 μ=4 → 8/3	표본분산 분모와 혼동
표본분산 $s^2=\Sigma(x_i-\bar{x})^2/(n-1)$	표본으로 모분산 추정	2,4,6 → 4	pandas **var()** 기본 ddof=1
표준편차=√분산	원래 단위의 산포	$s^2=4$ → s=2	분산과 단위 혼동
공분산=Σ((x-x̄)(y-y_bar))/(n-1)	두 변수 동행 방향	양수면 같은 방향 경향	크기는 단위 영향
상관 r=cov/(sX·sY)	선형 관계 강도 -1~1	r=-0.8 강한 음의 선형	인과로 해석 금지

확률 공식

공식	사용	예	실수
P(A^c)=1-P(A)	여사건	불량 0.03 → 정상 0.97	조건부확률과 혼동
P(A∪B)=P(A)+P(B)-P(A∩B)	합집합	중복을 한 번 뺌	교집합 누락
P(A|B)=P(A∩B)/P(B)	B가 주어진 조건	B 중 A 비율	분모 방향 반대
독립: P(A∩B)=P(A)P(B)	사건 독립	동전 두 번 앞면 1/4	배반과 혼동
Bayes: P(A|B)=P(B|A)P(A)/P(B)	원인 사후확률 갱신	검사 양성 후 질병확률	기저율 P(A) 누락

추정·검정 공식

공식	언제	예	실수
$SE(\bar{x})=\sigma/\sqrt{n}$ 또는 $s/\sqrt{n}$	표본평균 불확실성	s=10,n=100 → 1	s/ n으로 계산
μ 신뢰구간(σ 알려짐) $=\bar{x}\pm z\cdot\sigma/\sqrt{n}$	모분산 알려진 평균	95%면 z≈1.96	신뢰수준과 α 혼동
단일 $t=(\bar{x}-\mu0)/(s/\sqrt{n})$	모분산 미지 평균 검정	표본평균과 기준 비교	분모에 표준편차만 사용
$\chi^2=\Sigma(O-E)^2/E$	적합도·독립성	관측·기대도수 비교	기대도수를 분자에 사용
검정 결정	p≤α이면 H0 기각	p=.03, α=.05 → 기각	p를 H0 확률로 해석

회귀·분류 공식

공식	의미	예	실수
y_hat=b0_hat+Σ(bj_hat·xj)	회귀 예측	x에 값을 대입	계수와 p-value 혼동
$R^2=1-SSE/SST$	평균모형 대비 설명력	SSE가 작을수록 증가	인과·예측력으로 단정
$MSE=\Sigma(y-y_hat)^2/n$	평균 제곱오차	큰 오차 강조	RMSE와 단위 혼동
RMSE=√MSE	원래 단위 오차	MSE=9 → 3	다시 제곱함

공식	의미	예	실수
MAE=Σ|y-y_hat|/n	절대오차 평균	해석 쉬움	부호를 상쇄해 평균 내기
logit(p)=ln(p/(1-p))	로지스틱 선형식	β=ln2 → 오즈 2배	확률 2배로 해석

혼동행렬 계산 예제

TP=40, FP=10, FN=20, TN=30이면 전체 100이다.

- Accuracy=(40+30)/100=0.70.
- Precision=40/(40+10)=0.80.
- Recall=40/(40+20)=0.667.
- Specificity=30/(30+10)=0.75.
- F1=2×0.8×0.667/(0.8+0.667)≈0.727.

[자주 틀림] 분모를 외우기 어렵다면 질문으로 바꾼다. ‘예측 양성 중’은 Precision, ‘실제 양성 중’은 Recall이다.

나무·거리·군집·연관 공식

공식	사용	간단 예	실수
Entropy=-Σp log2(p)	분류 불순도	0.5/0.5 → 1	로그 밑과 부호 누락
Gini=1-Σp²	분류 불순도	0.5/0.5 → 0.5	분류 정확도와 혼동
Euclidean=√Σ(x-y)²	직선거리	(0,0)-(3,4)=5	스케일 영향 무시
Manhattan=Σ|x-y|	축 방향 거리	위 예=7	제곱 사용
Cosine=xy/(||x||||y||)	방향 유사도	문서 벡터	거리와 유사도 부호 혼동
Silhouette=(b-a)/max(a,b)	군집 응집·분리	a 작고 b 크면 1 근처	a,b 방향 반대
Support=P(A∩B)	함께 등장 비율	100건 중 20건=0.2	조건부확률로 계산
Confidence=P(B|A)	A 중 B 동시 비율	A 25건, 동시 20건=.8	방향 바꾸면 달라짐
Lift=Confidence/P(B)	독립 대비 연관	.8/.4=2	1을 강한 연관으로 오해

핵심 비교표

과대적합과 과소적합

구분	과대적합	과소적합
특징	학습은 좋고 검증은 나쁨	학습·검증 모두 나쁨
원인	지나친 복잡도·누수·작은 데이터	지나친 단순화·부족한 변수
해결	규제·가지치기·조기종료·데이터 증가	복잡도·유용 변수 증가·규제 완화

모수검정과 비모수검정

구분	모수검정	비모수검정
가정	분포·모수 가정이 상대적으로 강함	분포 가정이 약함
데이터	보통 연속형·정규성 등 조건	순서형·비정규·이상치 상황
장점	가정 충족 시 검정력 우수	강건하고 적용 범위 넓음

구분	모수검정	비모수검정
예	t, ANOVA, Pearson	Mann-Whitney, Wilcoxon, Kruskal, Spearman

상관과 회귀

구분	상관	회귀
목적	관계 방향·강도	종속변수 설명·예측
방향	기본적으로 대칭	독립·종속 역할 구분
단위	표준화 계수 -1~1	회귀계수는 단위 영향
인과	보장 안 함	설계 없이는 인과 보장 안 함

나무·랜덤포레스트·부스팅

항목	단일 나무	랜덤포레스트	부스팅
학습	한 나무	부트스트랩 병렬 다수 나무	이전 오차 순차 보완
장점	해석 쉬움	안정적·분산 감소	높은 예측 성능 가능
약점	과대적합	큰 모델·해석 저하	튜닝·노이즈 민감 가능

통계 검정 선택 기준

문제 문장 의사결정표

목적·데이터	조건	모수검정	비모수 대안	대표 H0
한 집단 평균 vs 기준	연속형, 한 표본	단일표본 t	부호·Wilcoxon 계열 검토	μ=μ0
독립 두 집단 평균	서로 다른 대상	독립표본 t, Welch t	Mann-Whitney U	μ1=μ2
같은 대상 전후 평균	쌍이 있는 자료	대응표본 t	Wilcoxon 부호순위	평균차=0
독립 3집단 이상 평균	한 범주요인	일원 ANOVA	Kruskal-Wallis	모든 집단 평균 동일
두 범주요인의 평균 영향	주효과·상호작용	이원 ANOVA	상황별 순위기반 방법	각 주효과·상호작용 없음
두 범주형 변수 관계	분할표	카이제곱 독립성	Fisher exact(작은 2×2)	두 변수 독립
관측 빈도와 기대 비율	한 범주형 변수	카이제곱 적합도	정확검정 검토	기대분포와 동일
두 연속형 관계	선형·조건 충족	Pearson 상관	Spearman·Kendall	ρ=0
연속형 결과 설명	독립변수 하나 이상	선형회귀	강건·비모수 회귀 검토	βj=0
이항 결과 설명	y가 0/1	로지스틱 회귀	-	βj=0, OR=1

t검정 선택 한 줄 규칙

1. 표본 하나와 기준값 비교 → 단일표본 t.
2. 서로 다른 사람 두 집단 → 독립표본 t.
3. 같은 사람 전후·짝지은 쌍 → 대응표본 t.
4. 독립 두 집단의 등분산을 가정하지 않으면 Welch t(**equal_var=False**).

ANOVA 해석

- H0는 모든 집단 평균이 같다.
- 유의하면 '적어도 한 집단 평균이 다름'까지만 알 수 있다.
- 어느 집단이 다른지는 Tukey 등 사후검정이 필요하다.
- 다중 t검정을 반복하면 제1종 오류가 누적된다.

검정 결론 문장 템플릿

- $p \le \alpha$: "유의수준 0.05에서 귀무가설을 기각한다. 따라서 [대립가설의 내용]을 뒷받침할 통계적 근거가 있다."
- $p > \alpha$: "유의수준 0.05에서 귀무가설을 기각하지 못한다. 따라서 [차이·관계]가 있다고 결론 내릴 통계적 근거가 충분하지 않다."

[주의] '귀무가설을 채택해 참으로 확정한다'는 표현보다 '기각하지 못한다'가 정확하다.

과목별 미니 테스트 40문제

1과목 미니 테스트

1-01 [분석 방법론·중]

CRISP-DM의 올바른 순서는?

1. 데이터 이해 → 업무 이해 → 모델링 → 데이터 준비 → 평가 → 전개
2. 업무 이해 → 데이터 이해 → 데이터 준비 → 모델링 → 평가 → 전개
3. 업무 이해 → 데이터 준비 → 데이터 이해 → 평가 → 모델링 → 전개
4. Sample → Explore → Modify → Model → Assess

1-02 [데이터 유형·하]

반정형 데이터로 가장 적절한 것은?

1. 관계형 데이터베이스의 고객 테이블
2. 고정된 열을 가진 CSV 매출표
3. 키와 중첩 구조를 가진 JSON 문서
4. 원본 음성 파일

1-03 [품질·중]

우편번호가 다섯 자리 형식은 지켰지만 실제 주소와 다른 값이 저장되었다. 직접적으로 낮은 품질 차원은?

1. 정확성
2. 완전성
3. 적시성
4. 유일성

1-04 [플랫폼·중]

HDFS에 대한 설명으로 옳은 것은?

1. 작은 파일을 매우 자주 임의 수정하는 데 최적화되어 있다.
2. 큰 파일을 블록으로 분산·복제 저장한다.
3. 관계형 조인을 위한 인메모리 SQL 엔진만을 뜻한다.
4. 이벤트 메시지 전달 전용 브로커다.

1-05 [개인정보·중]

가명정보에 대한 설명으로 옳은 것은?

1. 개인정보가 아니므로 아무 목적에나 사용할 수 있다.
2. 추가정보 없이 특정 개인을 알아보기 어렵지만 개인정보에 해당한다.
3. 반드시 원래 개인으로 복원이 불가능해야 한다.
4. 서로 다른 처리자 간 결합은 아무 절차 없이 가능하다.

1-06 [수집·하]

제공자가 정의한 규격과 인증 절차에 따라 데이터를 받는 방식은?

1. Open API
2. 포커스그룹 인터뷰
3. 계통표본추출
4. 총계처리

1-07 [ETL · 중]

ELT의 특징으로 옳은 것은?

1. 변환 후 적재한다.
2. 원본을 먼저 적재한 뒤 필요할 때 변환한다.
3. 추출 단계를 생략한다.
4. 데이터 품질 검증을 할 수 없다.

1-08 [조직 · 중]

현업 부서에 분석 인력을 배치하고 중앙 조직이 표준과 조정을 담당하는 구조는?

1. 집중형
2. 기능형
3. 분산형
4. 외주형만 가능

1-09 [CAP · 상]

CAP 관점의 가장 정확한 설명은?

1. 모든 분산 시스템은 평상시 세 속성 중 정확히 두 개만 가진다.
2. 네트워크 분할이 발생했을 때 일관성과 가용성 사이의 절충이 핵심이다.
3. 파티션 허용은 데이터베이스 테이블 분할만을 뜻한다.
4. 일관성과 정확성은 완전히 같은 품질 차원이다.

1-10 [과제 발굴 · 중]

보유 데이터를 탐색하고 프로토타입을 반복해 새로운 기회를 찾는 접근은?

1. 하향식 접근
2. 상향식 접근
3. 계통 추출
4. 연역적 검정만 가능한 접근

2과목 미니 테스트

2-01 [결측 · 중]

고소득자일수록 실제 소득값 때문에 소득 문항에 응답하지 않는 경향이 있다. 가장 가까운 결측 메커니즘은?

1. MCAR
2. MAR
3. MNAR
4. 완전관측

2-02 [스케일링 · 하]

표준화 후 일반적으로 기대되는 것은?

1. 최솟값 0, 최댓값 1
2. 평균 0, 표준편차 1
3. 중앙값 0, IQR 1만 보장
4. 모든 값이 양수

2-03 [차원축소 · 중]

PCA에 대한 설명으로 옳은 것은?

1. 기존 변수 중 하나만 임의 선택한다.
2. 잠재요인의 인과구조만 추정한다.
3. 기존 변수의 선형결합으로 분산을 많이 보존하는 성분을 만든다.
4. 종속변수가 반드시 필요하다.

2-04 [표본추출 · 중]

각 학년을 층으로 나누고 모든 학년에서 학생을 무작위 추출하는 방법은?

1. 군집추출
2. 층화추출
3. 계통추출
4. 편의추출

2-05 [확률 · 중]

두 사건 A와 B가 독립일 때 옳은 식은?

1. $P(A \cap B)=0$
2. $P(A|B)=0$
3. $P(A \cap B)=P(A)P(B)$
4. $P(A \cup B)=P(A)P(B)$

2-06 [표본분포 · 중]

표본표준편차가 12이고 표본크기가 36일 때 표본평균의 추정 표준오차는?

1. 0.333
2. 2
3. 6
4. 72

2-07 [가설검정 · 하]

p-value=0.03, α=0.05일 때 올바른 결론은?

1. 귀무가설이 참일 확률은 3%다.
2. 귀무가설을 기각한다.
3. 대립가설이 참일 확률은 97%다.
4. 제2종 오류 확률은 3%다.

2-08 [상관 · 중]

Pearson 상관계수가 0이라는 사실만으로 내릴 수 있는 결론은?

1. 두 변수는 어떠한 관계도 없다.

2. 선형 관계가 관측되지 않는다.
3. 두 변수는 독립이다.
4. 인과관계가 없다.

2-09 [불균형·중]

데이터 누수를 피하는 SMOTE 적용 시점은?

1. 전체 데이터에 적용 후 분할
2. 테스트 데이터에만 적용
3. 학습·검증 분할 후 학습 부분에 적용
4. 예측 결과에 적용

2-10 [분포·중]

포아송 분포의 대표적 성질은?

1. 평균 0, 분산 1
2. 평균과 분산이 λ
3. 값의 범위가 -∞부터 ∞
4. 연속형 대기시간 분포

3과목 미니 테스트

3-01 [회귀·중]

다중선형회귀에서 β2의 일반적 해석은?

1. 다른 설명변수를 고정할 때 x2가 1 증가할 때 y 평균 변화
2. x2가 y의 원인일 확률
3. y가 1 증가할 때 x2 변화
4. x2와 y의 상관계수와 항상 동일

3-02 [규제·중]

일부 계수를 정확히 0으로 만들어 변수 선택 효과를 낼 수 있는 방법은?

1. Ridge
2. Lasso
3. K-means
4. Bagging

3-03 [로지스틱·중]

로지스틱 회귀에서 exp(β1)=1.5의 의미는?

1. x1 1 증가 시 확률이 1.5배
2. x1 1 증가 시 오즈가 1.5배
3. x1 1 증가 시 로그오즈가 1.5배
4. 분류 정확도가 1.5배

3-04 [나무·하]

순수한 노드에서 지니 불순도는?

1. 0
2. 0.5
3. 1
4. 클래스 수와 항상 같음

3-05 [앙상블·중]

랜덤포레스트의 핵심 조합은?

1. 순차 잔차 보완과 하나의 변수만 사용
2. 부트스트랩 표본과 분할 변수 무작위 선택
3. 모든 나무가 동일한 전체 데이터·전체 변수만 사용
4. 메타모델 하나만 학습

3-06 [SVM·상]

SVM에서 C를 매우 크게 할 때 일반적 경향은?

1. 오분류 허용이 커지고 경계가 단순해진다.
2. 오분류 벌점이 커져 훈련자료에 더 맞출 수 있다.
3. 모든 계수가 0이 된다.
4. 커널을 사용할 수 없다.

3-07 [연관분석·중]

lift(A→B)=1의 의미는?

1. A와 B가 독립 수준
2. A가 B를 완전히 억제
3. 신뢰도가 100%
4. 지지도가 0

3-08 [군집·중]

임의 모양의 군집과 잡음을 함께 탐지하는 데 상대적으로 유리한 것은?

1. K-means
2. DBSCAN
3. 선형회귀
4. Naive Bayes

3-09 [시계열·중]

ARIMA(p,d,q)에서 d는?

1. 자기회귀 차수
2. 차분 횟수
3. 이동평균 차수
4. 계절 주기

3-10 [신경망·중]

Dropout의 주된 목적은?

1. 입력 변수를 영구 삭제
2. 학습 중 일부 뉴런을 무작위 비활성화해 과대적합 완화

3. 출력 확률을 0으로 고정
4. 결측값 평균 대치

4과목 미니 테스트

4-01 [분류지표·하]

실제 양성 100명 중 80명을 양성으로 맞혔다. Recall은?

1. 0.20
2. 0.80
3. 예측 양성 수가 없어 계산 불가
4. TN이 없어 계산 불가

4-02 [분류지표·중]

정상 메일을 스팸으로 잘못 차단하는 비용이 매우 클 때 우선 고려할 지표는?

1. 양성(스팸) Precision
2. 양성 Recall만
3. 회귀 RMSE
4. Silhouette

4-03 [ROC-AUC·중]

ROC-AUC 계산에 가장 적절한 입력은?

1. 모델의 연속 확률·점수
2. 학습 데이터의 행 번호
3. 손실함수 이름
4. 설명변수 개수만

4-04 [회귀지표·중]

큰 오차에 MAE보다 더 큰 벌점을 주는 지표는?

1. RMSE
2. Accuracy
3. Recall
4. Lift

4-05 [R^2·중]

R^2에 대한 설명으로 옳은 것은?

1. 어떤 데이터에서도 반드시 0~1이다.
2. 인과효과의 크기를 직접 뜻한다.
3. 테스트에서 기준 평균모형보다 나쁘면 음수가 될 수 있다.
4. 변수를 추가하면 조정 R^2도 반드시 증가한다.

4-06 [교차검증·중]

환자 한 명당 여러 행이 있을 때 같은 환자가 학습·검증에 나뉘지 않도록 하는 방법은?

1. Group K-Fold

2. 일반 무작위 행 분할만
3. LOF
4. Min-Max scaling

4-07 [과대적합·하]

학습 성능은 매우 높고 검증 성능이 낮다. 가장 가까운 상태는?

1. 과대적합
2. 과소적합
3. 완전한 일반화
4. 독립성

4-08 [모형선정·중]

하이퍼파라미터 선택에 테스트 데이터를 반복 사용하면 생기는 문제는?

1. 테스트 정보에 과적합될 수 있다.
2. 훈련 속도가 항상 빨라진다.
3. 클래스 불균형이 자동 해결된다.
4. 결측값이 자동 대치된다.

4-09 [드리프트·중]

입력 고객 연령 분포는 같지만 연령과 이탈 간 관계가 달라졌다. 가장 가까운 것은?

1. 데이터 드리프트만
2. 개념 드리프트
3. 표본오차가 0
4. 다중공선성만

4-10 [시각화·하]

두 연속형 변수의 관계를 확인하는 데 가장 적합한 기본 그래프는?

1. 산점도
2. 원그래프
3. 단일 숫자 카드
4. 덴드로그램만

종합 모의문제 40문제

문제

M-01 [1과목·DIKW·중]

온라인 주문 원자료를 집계해 “지난달보다 반품률이 2%p 증가했다”라고 표현한 단계는?

1. Data
2. Information
3. Knowledge
4. Wisdom

M-02 [1과목·조직·중]

분석 전문성을 한 조직에 모아 표준화하기 쉽지만 현업과의 거리가 생길 수 있는 구조는?

1. 집중형
2. 기능형
3. 분산형
4. 군집형 표본추출

M-03 [1과목·품질·중]

고객 한 명이 서로 다른 고객번호로 세 번 저장된 문제와 가장 직접적인 품질 차원은?

1. 적시성
2. 유일성
3. 유효성
4. 정확성만

M-04 [1과목·저장·중]

친구 관계, 계정 간 송금 관계처럼 연결 자체가 핵심인 데이터에 가장 자연스러운 NoSQL 유형은?

1. Key-Value
2. Document
3. Column-family
4. Graph

M-05 [1과목·개인정보·중]

옳지 않은 설명은?

1. 가명정보도 개인정보에 해당한다.
2. 익명정보는 합리적으로 개인을 알아볼 수 없는 정보다.
3. 가명정보는 통계작성 등 법정 목적에서 조건 아래 동의 없이 처리할 수 있다.
4. 가명정보는 목적과 보호조치 제한 없이 자유롭게 공개할 수 있다.

M-06 [1과목·방법론·중]

SEMMA 순서에서 세 번째 단계는?

1. Sample
2. Explore
3. Modify
4. Assess

M-07 [2과목·결측·상]

결측 여부가 다른 관측 변수인 연령으로 설명되며, 같은 연령 안에서는 결측값 자체와 무관하다고 가정한다. 가장 가까운 것은?

1. MCAR
2. MAR
3. MNAR
4. 완전무작위표본

M-08 [2과목·이상치·중]

Q1=10, Q3=18인 자료에 IQR 1.5배 규칙을 적용할 때 상한은?

1. 22
2. 26
3. 30
4. 32

M-09 [2과목·분산·중]

표본 1, 3, 5의 표본분산은?

1. 8/3
2. 4
3. 8
4. 2

M-10 [2과목·조건부확률·상]

질병 유병률이 1%, 민감도가 90%, 비질병자의 위양성률이 5%다. 양성일 때 질병일 확률에 가장 가까운 값은?

1. 0.01
2. 0.05
3. 0.154
4. 0.90

M-11 [2과목·신뢰구간·중]

다른 조건이 같을 때 95% 신뢰구간의 폭을 줄이는 방법은?

1. 표본크기를 줄인다.
2. 표본크기를 늘린다.
3. 신뢰수준을 99%로 높인다.
4. 표준편차를 크게 만든다.

M-12 [2과목·검정오류·중]

실제로 효과가 있는데 귀무가설을 기각하지 못한 경우는?

1. 제1종 오류
2. 제2종 오류

3. 유의수준
4. 검정력 자체

M-13 [2과목·검정선택·중]

동일한 환자 30명의 투약 전후 혈압 평균을 비교한다. 정규성 가정 아래 적절한 검정은?

1. 독립표본 t검정
2. 대응표본 t검정
3. 일원분산분석
4. 카이제곱 독립성검정

M-14 [2과목·ANOVA·중]

일원분산분석 결과 $p<0.05$일 때 직접 결론으로 가장 적절한 것은?

1. 모든 집단 평균이 서로 다르다.
2. 적어도 한 집단 평균이 다르다.
3. 가장 큰 평균의 집단이 원인이다.
4. 집단 분산이 모두 같다.

M-15 [2과목·비모수·중]

정규성을 만족하지 않는 독립 두 집단의 순위 차이를 비교하는 대표 검정은?

1. Mann-Whitney U
2. Wilcoxon 부호순위
3. 대응표본 t
4. McNemar

M-16 [2과목·상관·중]

두 변수의 순위가 대체로 같은 방향으로 움직이지만 관계가 직선은 아니다. 가장 적합한 기본 상관계수는?

1. Pearson만 가능
2. Spearman
3. 결정계수
4. VIF

M-17 [2과목·다변량·중]

관측된 설문 문항들의 공통된 잠재 구성개념을 찾는 목적에 더 가까운 것은?

1. PCA만
2. 요인분석
3. K-means
4. 선형판별만

M-18 [2과목·변환·중]

오른쪽 꼬리가 매우 길고 양수인 매출 변수의 큰 값 영향을 완화하려 한다. 우선 고려할 변환은?

1. 로그변환
2. 레이블 인코딩
3. 무작위 셔플
4. 원-핫 인코딩

M-19 [2·4과목·불균형·중]

양성 비율이 1%인 탐지 문제에서 다수 클래스만 모두 예측한 모델을 경계하기 위해 우선 확인할 것은?

1. Accuracy만
2. Recall·Precision·PR 곡선
3. R^2만
4. 군집 WCSS만

M-20 [2·3과목·누수·상]

다음 중 데이터 누수 가능성이 가장 큰 것은?

1. 학습 데이터 중앙값을 검증 데이터 결측치 대치에 사용
2. 전체 데이터의 평균으로 스케일링한 후 학습·검증 분할
3. 학습 데이터로 모델을 적합
4. 검증 점수로 후보 모델을 비교

M-21 [3과목·회귀가정·중]

잔차의 분산이 예측값이 커질수록 부채꼴로 증가한다. 위반 가능성이 큰 가정은?

1. 등분산성
2. 선형성만
3. 설명변수 독립성
4. 표본크기 고정

M-22 [3과목·다중공선성·중]

다중공선성이 심할 때 나타날 수 있는 현상은?

1. 회귀계수 추정의 분산이 커지고 부호가 불안정해진다.
2. 모든 잔차가 반드시 0이 된다.
3. R^2가 반드시 음수가 된다.
4. 종속변수가 범주형으로 바뀐다.

M-23 [3과목·로지스틱·중]

이항 로지스틱 회귀에 대한 설명으로 옳은 것은?

1. 종속변수는 반드시 연속형이다.
2. 선형예측값을 로짓 링크로 확률과 연결한다.
3. 최소제곱만으로 확률을 0~1에 제한한다.
4. 계수의 지수값은 평균 제곱오차다.

M-24 [3과목·엔트로피·중]

두 클래스 비율이 각각 0.5인 노드의 엔트로피(log2)는?

1. 0
2. 0.5
3. 1
4. 2

M-25 [3과목·나무·중]

정보이득에 대한 설명으로 옳은 것은?

1. 자식의 가중 불순도에서 부모 불순도를 뺀 값
2. 부모 불순도에서 자식의 가중 불순도를 뺀 값
3. 나무 깊이와 항상 같은 값
4. 회귀계수의 p-value

M-26 [3과목·앙상블·중]

배깅의 주된 효과는?

1. 여러 학습기를 병렬 결합해 분산을 줄인다.
2. 한 모델의 편향만 항상 0으로 만든다.
3. 이전 모델의 오차에만 순차 집중한다.
4. 설명변수를 한 개로 제한한다.

M-27 [3과목·부스팅·중]

그래디언트 부스팅에서 학습률을 작게 했을 때 흔한 조정은?

1. 트리 수를 늘려 보완한다.
2. 데이터 분할을 제거한다.
3. 모든 잔차를 0으로 고정한다.
4. 분류를 군집으로 바꾼다.

M-28 [3과목·SVM·상]

RBF SVM에서 gamma가 매우 커질 때 일반적 경향은?

1. 각 관측치 영향 범위가 넓어져 매우 매끄러워진다.
2. 각 관측치 영향 범위가 좁아져 복잡한 경계가 될 수 있다.
3. 항상 선형 커널과 같아진다.
4. C가 자동으로 0이 된다.

M-29 [3과목·K-means·중]

K-means 적용 전 특히 중요한 전처리는?

1. 거리 계산에 영향을 주는 변수 스케일 확인
2. 종속변수 원-핫 인코딩만
3. 시간 순서 역전
4. p-value를 1로 변환

M-30 [3과목·계층군집·중]

병합할 때 두 군집에서 가장 가까운 점 사이 거리를 쓰며 사슬 효과가 생기기 쉬운 연결법은?

1. Single
2. Complete
3. Average
4. Ward

M-31 [3과목·연관규칙·상]

100건 중 A 40건, B 50건, A와 B 동시 30건이다. confidence(A→B)와 lift(A→B)는?

1. 0.30, 0.60
2. 0.60, 0.75
3. 0.75, 1.50
4. 0.80, 1.60

M-32 [3과목·시계열·중]

비정상 시계열을 1회 차분한 뒤 ARMA를 적용한 모형 표기는?

1. ARIMA(p,1,q)
2. ARIMA(1,p,q)
3. ARIMA(p,q,1)
4. ARMA(p,1,q,0)

M-33 [3과목·베이지안·중]

베이지안 사후분포의 관계로 옳은 것은?

1. 사후분포 $\propto$ 우도 $\times$ 사전분포
2. 사후분포 = 표본평균만
3. 사전분포 $\propto$ 사후분포 $\times$ 우도
4. 우도는 관측 데이터와 무관

M-34 [4과목·혼동행렬·중]

TP=30, FP=10, FN=20, TN=40일 때 Precision은?

1. 0.50
2. 0.60
3. 0.75
4. 0.80

M-35 [4과목·평가곡선·중]

양성이 매우 희귀하고 양성 탐지 성능을 집중해서 보려 할 때 상대적으로 유용한 것은?

1. PR 곡선
2. 훈련 Accuracy만
3. R^2
4. Elbow만

M-36 [4과목·RMSE·중]

실제값 [2,4], 예측값 [1,7]일 때 RMSE는?

1. 2
2. $\sqrt{5}$
3. 4
4. 5

M-37 [4과목·Silhouette·중]

한 점의 같은 군집 평균거리 a=2, 가장 가까운 다른 군집 평균거리 b=5일 때 실루엣 계수는?

1. -0.6
2. 0.4

3. 0.6
4. 1.5

M-38 [4과목·교차검증·중]

시계열 예측의 검증 방법으로 가장 적절한 것은?

1. 미래 자료로 학습하고 과거 자료로만 검증
2. 시간 순서를 보존해 과거로 학습하고 이후 구간으로 검증
3. 모든 행을 무작위 섞어 미래가 학습에 들어가도 무관
4. 테스트 자료로 매 단계 하이퍼파라미터 선택

M-39 [4과목·모형선정·중]

동일한 데이터와 종속변수를 사용한 후보 모형의 AIC·BIC 해석으로 옳은 것은?

1. 일반적으로 작을수록 적합도와 복잡도 절충 측면에서 선호한다.
2. 클수록 무조건 예측 정확도가 높다.
3. 변수 수에 대한 벌점이 없다.
4. 서로 다른 데이터에서도 절대값만으로 무조건 비교한다.

M-40 [4과목·운영·중]

운영 중 입력 변수 분포 P(X)가 변한 현상은?

1. 데이터 드리프트
2. 개념 드리프트만
3. 완전 다중공선성
4. 표본평균 불편성

정답 및 상세 해설

1과목 미니 테스트 해설

1-01 정답 2

CRISP-DM은 업무 이해 → 데이터 이해 → 데이터 준비 → 모델링 → 평가 → 전개다. 1은 업무·데이터 이해 순서가 바뀌었고 3은 준비와 이해, 평가와 모델링 순서가 틀렸다. 4는 CRISP-DM이 아니라 SEMMA다.

1-02 정답 3

JSON은 키·값과 중첩 구조를 자체적으로 표현하는 반정형 데이터다. 1과 2는 고정된 표 구조의 정형 데이터이며 4는 고정 스키마가 약한 비정형 데이터다.

1-03 정답 1

실제 주소와 다르므로 정확성이 낮다. 완전성은 값의 누락, 적시성은 필요한 시점의 최신성, 유일성은 중복 여부다. 형식을 지켰다는 점은 유효성과 관련 있지만 실제 부합 문제의 직접 답은 정확성이다.

1-04 정답 2

HDFS는 큰 파일을 블록으로 나눠 여러 노드에 분산·복제 저장한다. 1은 HDFS의 약점에 가까우며 3은 처리·질의 엔진 설명, 4는 Kafka 같은 메시지 스트리밍 시스템 설명이다.

1-05 정답 2

가명정보는 추가정보 없이는 특정 개인을 알아보기 어렵게 처리했지만 여전히 개인정보다. 1은 익명정보와 혼동했고 3은 복원 불가능성을 요구하는 익명화 설명에 가깝다. 4는 결합 절차와 안전조치를 무시했다.

1-06 정답 1

Open API는 제공자가 정한 요청·응답 규격과 인증 방식으로 데이터를 제공한다. 2는 정성조사, 3은 표본추출, 4는 비식별화·집계 방법이다.

1-07 정답 2

ELT는 Extract → Load → Transform이므로 원본을 먼저 적재하고 이후 변환한다. 1은 ETL, 3은 추출 단계를 잘못 생략했고 4는 품질 검증 가능 여부와 무관한 단정이다.

1-08 정답 3

분산형은 분석 인력을 현업에 배치하면서 중앙이 표준과 조정을 담당한다. 집중형은 별도 전문조직 중심, 기능형은 현업 부서가 독자적으로 분석하는 구조다. 4는 일반적 조직 구조 분류가 아니다.

1-09 정답 2

CAP의 핵심은 네트워크 분할 상황에서 일관성과 가용성 사이에 절충이 생긴다는 점이다. 1은 '항상 정확히 둘'이라는 과도한 단순화, 3은 partition tolerance의 의미를 오해했고 4는 서로 다른 개념을 동일시했다.

1-10 정답 2

데이터 탐색과 프로토타이핑에서 과제를 발견하는 방식은 상향식이다. 하향식은 업무 문제에서 분석 과제로 좁혀 가며 3은 표본추출, 4는 상향식의 탐색적 성격을 부정한다.

2과목 미니 테스트 해설

2-01 정답 3

결측 여부가 응답하지 않은 실제 소득 자체와 관련되므로 MNAR다. MCAR은 어떤 값과도 무관하며 MAR은 다른 관측 변수로 결측을 설명할 수 있는 경우다. 4는 결측 메커니즘이 아니다.

2-02 정답 2

일반적인 Z 표준화는 평균 0, 표준편차 1로 만든다. 1은 Min-Max, 3은 Robust scaling의 중심 개념에 가깝고 4처럼 모든 값이 양수가 될 필요는 없다.

2-03 정답 3

PCA는 기존 변수의 선형결합인 주성분을 만들고 분산을 최대한 보존한다. 1은 변수 선택, 2는 잠재요인 설명을 강조하는 요인분석에 가깝고 4와 달리 비지도 차원축소이므로 종속변수가 필수는 아니다.

2-04 정답 2

학년이라는 층을 만들고 모든 층에서 표본을 뽑으므로 층화추출이다. 군집추출은 일부 군집을 선택하며 계통추출은 일정 간격, 편의추출은 접근 가능한 대상을 뽑는다.

2-05 정답 3

독립이면 $P(A \cap B)=P(A)P(B)$다. 1은 배반일 때의 교집합, 2는 일반적으로 성립하지 않으며 4는 합집합 공식이 아니다.

2-06 정답 2

표준오차는 $s/\sqrt{n}=12/\sqrt{36}=12/6=2$다. 1은 잘못된 나눗셈, 3은 $\sqrt{n}$만, 4는 곱셈에서 나온 오답이다.

2-07 정답 2

$p=0.03 \leq 0.05$이므로 귀무가설을 기각한다. 1과 3은 p-value를 가설이 참일 확률로 잘못 해석했고 4는 p-value와 제2종 오류 β를 동일시했다.

2-08 정답 2

Pearson $r=0$은 선형 상관이 관측되지 않는다는 뜻이다. 비선형 관계가 있을 수 있어 1은 과도하며, $r=0$만으로 독립이나 인과 부재를 결론 낼 수 없어 3과 4도 틀리다.

2-09 정답 3

먼저 학습·검증을 분리하고 학습 부분에만 SMOTE를 적용해야 검증 정보 누수를 막는다. 1은 전체 분포 정보를 학습에 흘리고 2는 테스트 분포를 바꾸며 4는 전처리 시점이 아니다.

2-10 정답 2

포아송 분포는 평균과 분산이 모두 λ인 사건 횟수 분포다. 1은 표준정규, 3은 포아송의 음이 아닌 정수 범위와 맞지 않고 4는 지수분포에 가깝다.

3과목 미니 테스트 해설

3-01 정답 1

다중회귀 계수는 다른 설명변수를 고정할 때 해당 변수가 1 증가하는 경우 종속변수 조건부 평균의 변화를 뜻한다. 2는 인과확률로 과해석했고 3은 방향이 반대이며 4는 표준화·단순회귀의 일부 관계를 일반화한 오답이다.

3-02 정답 2

Lasso의 L1 벌점은 일부 계수를 정확히 0으로 만들 수 있다. Ridge의 L2는 보통 0에 가깝게 축소하고, K-means는 군집, Bagging은 앙상블이다.

3-03 정답 2

exp(β1)=1.5는 다른 조건이 같을 때 x1 1단위 증가 시 오즈가 1.5배가 된다는 뜻이다. 확률 배수·정확도 배수가 아니며 로그오즈의 변화량 자체는 β1이다.

3-04 정답 1

한 클래스만 있는 순수 노드는 $\Sigma p^2=1$이므로 Gini=1-1=0이다. 0.5는 두 클래스가 반반일 때, 1이나 클래스 수와 같다는 설명은 틀리다.

3-05 정답 2

랜덤포레스트는 부트스트랩 표본을 만들고 각 분할에서 무작위 변수 후보를 사용한다. 1은 부스팅과 혼동했고 3은 나무 간 상관을 높이며 4는 스태킹의 메타모델 일부 설명이다.

3-06 정답 2

C가 크면 오분류 벌점이 커져 훈련자료를 더 엄격히 맞추려 하고 복잡한 경계가 될 수 있다. 1은 C가 작은 방향에 가깝고 3과 4는 C의 의미와 무관하다.

3-07 정답 1

Lift=1은 A를 알더라도 B 발생이 기저확률과 같은 독립 수준이다. 음의 연관은 1 미만, 양의 연관은 1 초과다. 신뢰도·지지도 값은 lift 하나로 확정할 수 없다.

3-08 정답 2

DBSCAN은 밀도로 연결된 영역을 찾아 임의 모양 군집과 잡음을 처리할 수 있다. K-means는 중심 기반 구형 군집에 가깝고 3·4는 군집 알고리즘이 아니다.

3-09 정답 2

ARIMA(p,d,q)에서 p는 AR 차수, d는 차분 횟수, q는 MA 차수다. 계절 주기는 별도 s로 표현한다.

3-10 정답 2

Dropout은 학습 중 일부 뉴런을 무작위로 비활성화해 특정 경로 의존과 과대적합을 줄인다. 영구 변수 삭제·출력 고정·결측 대치가 아니다.

4과목 미니 테스트 해설

4-01 정답 2

Recall=TP/(TP+FN)=잡아낸 실제 양성/전체 실제 양성=80/100=0.8이다. TN은 필요하지 않으며 예측 양성 전체는 Precision 계산에 필요하다.

4-02 정답 1

정상 메일을 스팸으로 잘못 차단하는 것은 양성 예측의 FP다. 양성 Precision을 높이면 스팸으로 예측한 것 중 실제 스팸 비율을 높여 FP를 줄이는 방향이 된다. 2만 보면 놓치지 않는 데 집중해 FP가 늘 수 있고 3·4는 문제 유형이 다르다.

4-03 정답 1

ROC-AUC는 임계값을 바꿔 순위 성능을 평가하므로 연속 확률·점수가 적절하다. 행 번호, 손실 이름, 변수 개수는 ROC 점수가 아니다.

4-04 정답 1

RMSE는 오차를 제곱하므로 큰 오차에 MAE보다 민감하다. Accuracy와 Recall은 분류, Lift는 연관규칙 지표다.

4-05 정답 3

테스트 자료에서 모델이 평균 예측 기준보다 나쁘면 R^2가 음수가 될 수 있다. 1은 범위를 잘못 단정했고 2는 설명력을 인과로 오해했다. 조정 R^2는 불필요한 변수를 추가하면 감소할 수 있어 4도 틀리다.

4-06 정답 1

Group K-Fold는 같은 환자 그룹이 학습과 검증에 동시에 들어가지 않게 한다. 2는 환자 정보 누수가 가능하고 3은 이상치 탐지, 4는 스케일링이다.

4-07 정답 1

학습에 비해 검증 성능이 크게 떨어지는 패턴은 과대적합이다. 과소적합은 학습·검증 모두 나쁘며 3·4는 설명과 맞지 않는다.

4-08 정답 1

테스트 성능을 보고 계속 모델을 바꾸면 테스트 정보에도 과적합되어 최종 점수가 낙관적으로 편향될 수 있다. 나머지는 테스트 반복 사용이 자동으로 해결하지 않는다.

4-09 정답 2

P(X)는 비슷하지만 P(y|X), 즉 입력과 결과의 관계가 변했으므로 개념 드리프트다. 데이터 드리프트는 주로 입력 분포 변화이며 3·4와 무관하다.

4-10 정답 1

두 연속형 변수의 관계는 산점도가 기본이다. 원그래프는 구성비, 숫자 카드는 단일 KPI, 덴드로그램은 계층적 군집을 보여준다.

종합 모의문제 해설

M-01 정답 2

원자료를 집계하고 비교 의미를 부여했으므로 Information이다. Data는 가공 전 사실, Knowledge는 반복 패턴·규칙, Wisdom은 행동·판단 수준이다.

M-02 정답 1

집중형은 전문 인력과 표준을 모으기 쉽지만 현업 소통이 약해질 수 있다. 기능형은 현업 자체 분석, 분산형은 현업 배치와 중앙 조정의 결합이며 4는 조직 구조가 아니다.

M-03 정답 2

동일 실체가 여러 번 존재하므로 유일성 문제다. 적시성은 시점, 유효성은 규칙·형식, 정확성은 실제 값과의 부합이다.

M-04 정답 4

Graph DB는 노드와 관계를 직접 표현해 연결 탐색에 적합하다. Key-Value는 단순 조회, Document는 문서 구조, Column-family는 대규모 열 묶음 저장에 강하다.

M-05 정답 4

가명정보는 목적·안전조치·결합 절차 등 제한을 받아 자유 공개할 수 없다. 1~3은 가명정보와 익명정보의 핵심 차이를 올바르게 설명한다.

M-06 정답 3

SEMMA는 Sample → Explore → Modify → Model → Assess다. 따라서 세 번째는 Modify이며 나머지는 각각 1·2·5번째다.

M-07 정답 2

다른 관측 변수인 연령으로 결측을 설명할 수 있으므로 MAR다. MCAR은 관측·미관측과 무관, MNAR은 결측값 자체와 관련, 4는 표본추출 용어다.

M-08 정답 3

IQR=18-10=8, 상한=Q3+1.5×IQR=18+12=30이다. 22·26·32는 IQR 배수 또는 기준점을 잘못 계산한 값이다.

M-09 정답 2

평균은 3이고 제곱편차합은 4+0+4=8이다. 표본분산은 n-1=2로 나눠 4다. 8/3은 모집단분산, 8은 제곱편차합, 2는 표준편차다.

M-10 정답 3

P(질병|양성)=0.9×0.01/[0.9×0.01+0.05×0.99]=0.009/0.0585≈0.154다. 1은 기저율, 2는 위양성률, 4는 민감도를 사후확률로 잘못 쓴 값이다.

M-11 정답 2

표본크기를 늘리면 표준오차가 $1/\sqrt{n}$ 비율로 줄어 구간이 좁아진다. 1·4는 폭을 넓힐 수 있고 3은 더 높은 신뢰수준이므로 임계값이 커져 폭이 넓어진다.

M-12 정답 2

H0가 실제로 거짓인데 기각하지 못하면 제2종 오류 β다. 제1종 오류는 참인 H0를 기각, 유의수준은 제1종 오류 허용확률, 검정력은 1-β다.

M-13 정답 2

같은 환자의 전후 값은 쌍을 이루므로 대응표본 t검정이다. 독립표본 t는 서로 다른 집단, ANOVA는 보통 3집단 이상, 카이제곱은 범주형 빈도 관계에 쓴다.

M-14 정답 2

ANOVA 유의 결과는 적어도 한 평균이 다르다는 뜻이다. 모든 쌍이 다른지와 어느 집단이 다른지는 사후검정이 필요하며 인과와 등분산을 결과만으로 확정할 수 없다.

M-15 정답 1

Mann-Whitney U는 독립 두 집단의 대표 비모수 비교다. Wilcoxon 부호순위와 대응표본 t는 쌍 자료, McNemar는 대응된 이항 범주 자료에 사용한다.

M-16 정답 2

Spearman은 순위 기반으로 단조 관계를 평가한다. Pearson은 선형 관계 중심이며 3은 회귀 설명력, 4는 다중공선성 진단이다.

M-17 정답 2

잠재 구성개념을 설명하려는 목적은 요인분석에 가깝다. PCA는 전체 분산 보존 압축, K-means는 군집, 선형판별은 지도 분류·차원축소에 가깝다.

M-18 정답 1

양수이고 오른쪽 꼬리가 긴 변수는 로그변환으로 큰 값 영향과 왜도를 완화할 수 있다. 2·4는 범주형 인코딩, 3은 분포 모양을 해결하는 변환이 아니다.

M-19 정답 2

양성 1%에서는 모두 음성으로 예측해도 Accuracy가 99%일 수 있다. 양성 Precision·Recall과 PR 곡선이 더 직접적이며 R^2와 WCSS는 다른 문제 지표다.

M-20 정답 2

분할 전에 전체 평균을 계산하면 검증 분포 정보가 학습 전처리에 들어간다. 1은 학습에서 구한 규칙을 검증에 적용하는 올바른 흐름이며 3·4는 일반적 학습·선택 절차다.

M-21 정답 1

잔차 폭이 예측값에 따라 달라지는 부채꼴은 이분산 신호다. 선형성 위반은 곡선 패턴, 3은 표현 자체가 모호하고 4는 회귀 가정이 아니다.

M-22 정답 1

다중공선성은 계수 표준오차를 키워 부호·유의성이 불안정해질 수 있다. 잔차 0, R^2 음수, 종속변수 유형 변화가 필연적으로 발생하지는 않는다.

M-23 정답 2

로지스틱 회귀는 선형예측값을 로짓 링크로 이항확률과 연결한다. 종속변수는 이항 범주이며 최소제곱만 사용하는 설명과 exp(β)를 MSE로 보는 설명은 틀리다.

M-24 정답 3

H=-[0.5log2(0.5)+0.5log2(0.5)]=1이다. 0은 순수 노드, 0.5는 지니 불순도, 2는 계산 오류다.

M-25 정답 2

정보이득은 부모 불순도-자식의 가중 불순도다. 1은 부호가 반대이고 3·4는 정보이득 정의와 무관하다.

M-26 정답 1

배깅은 부트스트랩 기반 학습기를 병렬 결합해 분산을 줄인다. 편향을 항상 0으로 만들 수 없고 3은 부스팅, 4는 배깅의 필수 조건이 아니다.

M-27 정답 1

작은 학습률은 한 단계의 기여를 줄이므로 보통 더 많은 트리로 보완한다. 2~4는 학습률 조정과 논리적으로 연결되지 않는다.

M-28 정답 2

RBF gamma가 크면 한 점의 영향 범위가 좁아져 경계가 복잡해지고 과대적합할 수 있다. 1은 gamma가 작은 경향이며 3·4는 자동으로 성립하지 않는다.

M-29 정답 1

K-means는 거리 기반이라 단위가 큰 변수가 군집을 지배할 수 있어 스케일 확인이 중요하다. 2~4는 K-means 거리 문제를 해결하지 않는다.

M-30 정답 1

Single linkage는 군집 간 최소거리를 사용해 점들이 길게 연결되는 사슬 효과가 생기기 쉽다. Complete는 최대거리, Average는 평균거리, Ward는 군집 내 제곱합 증가를 사용한다.

M-31 정답 3

confidence=30/40=0.75, P(B)=50/100=0.5이므로 lift=0.75/0.5=1.5다. 다른 선택지는 지지도 0.3이나 분모를 잘못 사용했다.

M-32 정답 1

ARIMA(p,d,q)에서 d가 차분 횟수이므로 1회 차분은 ARIMA(p,1,q)다. 다른 선택지는 p·d·q 위치를 바꿨다.

M-33 정답 1

사후분포는 우도와 사전분포의 곱에 비례하며 정규화 상수로 나눈다. 2는 정보를 지나치게 축소했고 3은 관계를 잘못 배치했으며 4와 달리 우도는 관측 데이터의 모수별 가능도를 표현한다.

M-34 정답 3

Precision=TP/(TP+FP)=30/40=0.75다. 0.60은 Recall=30/(30+20), 나머지는 분모를 잘못 잡은 값이다.

M-35 정답 1

희귀 양성에서는 Precision과 Recall의 절충을 보여주는 PR 곡선이 민감하다. 훈련 Accuracy는 불균형에 기만적일 수 있고 R^2는 회귀, Elbow는 군집 수 선택이다.

M-36 정답 2

오차는 1과 -3, 제곱오차는 1과 9다. MSE=5, RMSE=$\sqrt{5}$다. 1은 MAE=(1+3)/2=2, 3·4는 제곱·제곱근 단계를 혼동했다.

M-37 정답 3

s=(b-a)/max(a,b)=(5-2)/5=0.6이다. 부호를 반대로 하면 -0.6, 분모·분자를 잘못 쓰면 0.4나 1.5가 된다.

M-38 정답 2

시계열은 과거로 학습하고 뒤 시점으로 검증해 실제 예측 방향을 보존한다. 1은 시간 역전, 3은 미래 누수, 4는 테스트 과적합을 만든다.

M-39 정답 1

AIC·BIC는 적합도와 복잡도 벌점을 함께 반영하며 비교 가능한 후보에서는 작을수록 선호한다. 2는 예측성능을 보장하지 않고 3은 벌점을 부정하며 4는 비교 조건을 무시했다.

M-40 정답 1

입력 분포 P(X)의 변화는 데이터 드리프트다. 개념 드리프트는 주로 P(y|X) 변화이며 3·4는 운영 분포 변화 개념이 아니다.

참고 출처와 배포 안내

자료 조사 기준

- 조사·업데이트 기준일: 2026-07-17.
- 공식 범위와 시험 구조는 한국데이터산업진흥원 데이터자격시험의 빅데이터분석기사 안내를 최우선으로 반영했다.
- 2026년 일정은 국가데이터처의 빅데이터분석기사 검정일정을 확인했다.
- 개인정보 부분은 현행 개인정보 보호법과 개인정보보호위원회의 2026년 가명정보 처리 가이드라인을 확인했다.
- 최근 경향은 제11·12회 수험 후기를 참고했으며 공식 출제 사실이 아닌 내용에는 '최근 복원 문제 기준'으로 표시했다.

주요 참고 링크

- 한국데이터산업진흥원 데이터자격시험 빅데이터분석기사: https://www.dataq.or.kr/www/sub/a_07.do
- 빅데이터분석기사 실기 공식 체험환경: https://dataq.goorm.io/exam/3/체험하기/quiz/1
- 실기 체험환경 가이드(2025-06-05): https://kr.object.gov-ncloudstorage.com/dataq/dataq-10th/%5BK-DATA%5D%20빅데이터분석기사%20실기%20체험환경%20가이드_250605.pdf
- 2026년 공식 검정일정: https://mods.go.kr/menu.es?mid=a10411020100
- 국가법령정보센터 개인정보 보호법: https://www.law.go.kr/법령/개인정보보호법
- 개인정보보호위원회 가명정보 처리 가이드라인(2026.3): https://www.pipc.go.kr/np/cop/bbs/selectBoardArticle.do?bbsId=BS217&mCode=G010030000&nttId=11931
- SciPy 통계함수 공식 문서: https://docs.scipy.org/doc/scipy/reference/stats.html
- scikit-learn 평가 지표 공식 문서: https://scikit-learn.org/stable/modules/model_evaluation.html
- statsmodels 공식 API: https://www.statsmodels.org/stable/api.html
- [최근 복원 문제 기준] 제12회 실기 합격 후기: https://fasman-developer.tistory.com/36
- [최근 복원 문제 기준] 제11회 실기 합격 후기: https://ramin0119.tistory.com/115
- [최근 후기] 제12회 필기 후기: https://velog.io/@knifeonfrog/제-12회-빅분기-필기-후기-공부방법

배포용 면책문구

본 자료는 빅데이터분석기사 수험생의 학습을 돕기 위해 제작된 비공식 요약자료입니다. 실제 시험의 출제범위와 시험환경은 변경될 수 있으므로 한국데이터산업진흥원 데이터자격시험의 공식 시험안내와 해당 회차 공지를 반드시 함께 확인해야 합니다.

본 자료만으로 합격을 보장할 수 없으며, 기본 개념 학습과 기출·복원문제 풀이를 병행하는 것을 권장합니다. 모든 설명과 문제는 여러 공개 자료와 표준 개념을 바탕으로 독자적으로 작성했으며 특정 교재·강의·블로그의 문장을 복제하지 않았습니다.

개인 학습용으로만 사용할 수 있으며 무단 재배포·판매·수정 후 재배포를 금지합니다.

- 자료 제작자: 상원.zip
- 블로그명: rongleader
- 이메일·수정본 문의: rongleader@naver.com
- 자료 업데이트 기준일: 2026-07-17